

**PROPOSAL PEMBELAJARAN MESIN
DETEKSI FRAUD TRANSAKSI KARTU KREDIT
MENGUNAKAN MACHINE LEARNING**

Dosen Pengampu :
Abu Salam M.Kom



Disusun oleh:

Sabrina Angel Lilga Putri Maharani – A11.2024.15596

**PROGRAM STUDI TEKNIK INFORMATIKA
UNIVERSITAS DIAN NUSWANTORO SEMARANG
TAHUN 2026/2027**

DAFTAR ISI

DAFTAR ISI.....	1
DAFTAR TABEL	3
DAFTAR GAMBAR.....	4
BAB I PENDAHULUAN	5
1.1 Latar Belakang	5
1.2 Mengapa Machine Learning Diperlukan?.....	5
1.3 Definisi Learning Task.....	6
BAB II RUMUSAN MASALAH.....	7
2.1 Identifikasi Masalah.....	7
2.2 Tujuan Proyek	7
2.3 Hipotesis Awal.....	7
BAB III ANALISIS DATASET DAN REPRESENTASI DATA	9
3.1 Informasi Dataset.....	9
3.2 Deskripsi Fitur	10
3.3 Analisis Karakteristik Data	10
3.3.1 Distribusi Label (Target)	10
3.3.2 Potensi Bias Data	11
3.3.3 Feature vs Target Relationship	11
3.4 Identifikasi Tantangan Dataset	12
BAB IV PERANCANGAN PIPELINE MACHINE LEARNING	14
4.1 Gambaran Umum Pipeline	14
4.2 Tahap 1 – Exploratory Data Analysis (EDA).....	16
4.3 Tahap 2 – Data Preprocessing	16
4.4 Tahap 3 – Feature Engineering.....	17
4.5 Tahap 4 – Data Splitting Strategy.....	18
4.6 Pipeline Workflow (End-toEnd).....	19

BAB V STRATEGI PEMODELAN DAN EKSPERIMEN	20
5.1 Algoritma yang Digunakan.....	20
5.2 Logistic Regression (Baseline Model).....	20
5.3 Random Forest Classifier (Model Utama)	21
5.4 Rancangan Eksperimen dan Hyperparameter Tuning	22
5.5 Metrik Evaluasi	22
5.6 Rencana Analisis Overfitting dan Bias-Variance Tradeoff	24
BAB VI RENCANA DEPLOYMENT MODEL.....	26
6.1 Bentuk Deployment.....	26
6.2 Alur Inference: Input→ Model → Output	26
6.3 Struktur Sistem dan Arsitektur Sederhana	28
BAB VII TIMELINE Pengerjaan Proyek	30
BAB VIII KESIMPULAN	31
DAFTAR PUSTAKA	32

DAFTAR TABEL

Tabel 1 Informasi Dataset.....	9
Tabel 2 Deskripsi Fitur Dataset	10
Tabel 3 Distribusi Label	11
Tabel 4 Tantangan Dataset.....	12
Tabel 5 Gambaran Umum Pipeline Machine	15
Tabel 6 Tahapan Data Preprocessing	17
Tabel 7 Feature Engineering yang Digun.....	18
Tabel 8 Strategi Data Splitting.....	19
Tabel 9 Konfigurasi Logistic Regressio	21
Tabel 10 Konfigurasi Random Forest	22
Tabel 11 Rancangan Eksperimen dan Hyper.....	22
Tabel 12 Metrik Evaluasi Model.....	23
Tabel 13 Analisis Overfitting dan Bias- Variance.....	24
Tabel 14 Bentuk Deployment Model	26
Tabel 15 Alur Proses Inference Sistem	27
Tabel 16 Struktur dan Fungsi Komponen Sistem	29
Tabel 17 Timeline Pengerjaan Proyek.....	30

DAFTAR GAMBAR

Gambar 1 Pipeline Machine Learning	15
Gambar 2 Diagram Alur Inference Sistem	28

BAB I

PENDAHULUAN

1.1 Latar Belakang

Penipuan kartu kredit (credit card fraud) merupakan salah satu bentuk kejahatan finansial yang paling merugikan di era digital. Sebuah bank di Eropa mencatat 284.807 transaksi kartu kredit dalam dua hari pada September 2013, di mana 492 transaksi (0,17%) terbukti merupakan penipuan. Meski persentasenya sangat kecil, kerugian finansialnya sangat besar — baik bagi nasabah yang menjadi korban maupun institusi keuangan yang harus menanggung biaya pengembalian dana.

Data historis menunjukkan bahwa transaksi penipuan memiliki pola yang dapat dibedakan dari transaksi sah, meskipun pola tersebut sangat kompleks dan tersembunyi di dalam kombinasi banyak fitur sekaligus. Sistem deteksi konvensional berbasis aturan tidak mampu menangkap kompleksitas ini secara otomatis. Pertanyaan utama yang ingin dijawab: dapatkah model Machine Learning mendeteksi secara akurat apakah suatu transaksi kartu kredit merupakan penipuan, berdasarkan fitur-fitur transaksi yang tersedia?

1.2 Mengapa Machine Learning Diperlukan?

Pendekatan deteksi fraud secara tradisional umumnya menggunakan metode rule-based, yaitu dengan menetapkan aturan tertentu seperti “jika jumlah transaksi melebihi batas tertentu maka dianggap fraud”. Pendekatan ini memiliki keterbatasan karena hanya mampu menangkap pola sederhana dan satu dimensi, serta tidak mampu mempertimbangkan interaksi kompleks antar berbagai fitur transaksi.

Selain itu, sistem berbasis aturan memerlukan pembaruan manual setiap kali muncul pola fraud baru, sehingga kurang adaptif terhadap perubahan perilaku pelaku kejahatan.

Sebaliknya, Machine Learning mampu mempelajari pola dari data historis secara otomatis dan menangkap hubungan non-linear antar fitur seperti V1–V28, Amount, dan Time secara simultan. Model Machine Learning juga dapat menghasilkan probabilitas

prediksi, sehingga memungkinkan penentuan threshold yang lebih fleksibel sesuai kebutuhan bisnis.

Dengan demikian, Machine Learning lebih unggul dalam mendeteksi fraud karena kemampuannya dalam menangani kompleksitas data, adaptasi terhadap pola baru, serta analisis interaksi fitur yang tidak dapat dilakukan oleh pendekatan rule-based.

1.3 Definisi Learning Task

Permasalahan dalam penelitian ini termasuk dalam kategori Supervised Learning, khususnya klasifikasi biner. Hal ini dikarenakan dataset yang digunakan telah memiliki label (target) yang jelas, yaitu kolom Class, sehingga model dapat dilatih untuk mempelajari hubungan antara fitur input dan label output.

Target atau label yang digunakan adalah variabel Class, dengan nilai:

- 0 untuk transaksi sah (non-fraud)
- 1 untuk transaksi penipuan (fraud)

Adapun fitur input yang digunakan terdiri dari 30 variabel numerik, yaitu Time, Amount, serta V1 hingga V28 yang merupakan hasil transformasi Principal Component Analysis (PCA).

Dataset ini memiliki karakteristik khusus berupa ketidakseimbangan kelas yang sangat ekstrem, di mana hanya sekitar 0,17% data merupakan transaksi fraud. Kondisi ini memerlukan pendekatan khusus dalam proses pelatihan model agar tidak bias terhadap kelas mayoritas.

BAB II

RUMUSAN MASALAH

2.1 Identifikasi Masalah

- Bagaimana membangun model Machine Learning yang akurat untuk mendeteksi transaksi penipuan kartu kredit berdasarkan fitur-fitur transaksi?
- Algoritma klasifikasi mana yang memberikan performa terbaik untuk kasus deteksi fraud — Logistic Regression atau Random Forest?
- Bagaimana menangani ketidakseimbangan kelas yang ekstrem (0,17% fraud vs 99,83% sah) agar model dapat belajar secara optimal?
- Metrik evaluasi apa yang paling tepat untuk mengukur kinerja model dalam skenario di mana false negative (fraud tidak terdeteksi) sangat merugikan?

2.2 Tujuan Proyek

Tujuan dari penelitian ini adalah sebagai berikut:

- Tujuan Utama
Membangun model Machine Learning berbasis klasifikasi biner yang mampu mendeteksi apakah suatu transaksi kartu kredit termasuk penipuan (fraud) atau transaksi sah berdasarkan fitur-fitur yang tersedia dalam dataset.
- Tujuan Komparatif
Membandingkan performa dua algoritma Machine Learning, yaitu Logistic Regression dan Random Forest, dalam mendeteksi transaksi fraud menggunakan metrik evaluasi seperti Recall, Precision, F1-Score, dan ROC-AUC.
- Tujuan Analitik
Mengidentifikasi fitur-fitur yang paling berpengaruh terhadap prediksi fraud menggunakan pendekatan feature importance pada model Random Forest.
- Tujuan Deployment
Merancang sistem deployment berbasis API menggunakan FastAPI agar model dapat digunakan untuk melakukan prediksi transaksi secara real-time.

2.3 Hipotesis Awal

Berdasarkan karakteristik dataset dan pendekatan yang digunakan, beberapa hipotesis awal dalam penelitian ini adalah sebagai berikut:

1. Model Random Forest diperkirakan akan menghasilkan performa yang lebih baik dibandingkan Logistic Regression, khususnya dalam metrik Recall dan ROC-AUC, karena kemampuannya dalam menangkap hubungan non-linear antar fitur serta lebih robust terhadap distribusi data yang kompleks dan tidak seimbang.
2. Penerapan preprocessing yang tepat, termasuk scaling fitur dan penanganan ketidakseimbangan data menggunakan parameter *class_weight*, diperkirakan dapat meningkatkan kemampuan model dalam mendeteksi transaksi fraud pada kelas minoritas.
3. Beberapa fitur hasil transformasi PCA, seperti V10, V12, V14, dan V17, diperkirakan memiliki kontribusi signifikan dalam proses deteksi fraud berdasarkan pola yang ditemukan pada penelitian sebelumnya.
4. Dengan strategi pemodelan dan evaluasi yang tepat, model diharapkan mampu mencapai performa yang baik serta Recall yang tinggi dalam mendeteksi transaksi fraud.

BAB III

ANALISIS DATASET DAN REPRESENTASI DATA

3.1 Informasi Dataset

Berikut adalah informasi umum mengenai dataset Credit Card Fraud Detection yang digunakan dalam penelitian ini, meliputi jumlah data, jumlah fitur, serta karakteristik utama dataset:

Atribut	Detail
Nama Dataset	Credit Card Fraud Detection
Sumber	Kaggle — Platform dataset publik terkurasi
Link Dataset	https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud
Pembuat	Machine Learning Group — ULB (Université Libre de Bruxelles, Belgium)
Lisensi	Open Database License (ODbL) — bebas digunakan untuk riset & pendidikan
Format File	CSV (Comma-Separated Values)
Dimensi Data	284.807 baris (transaksi) x 31 kolom (fitur)
Periode Data	September 2013 — transaksi kartu kredit nasabah bank Eropa selama 2 hari
Jenis Data	Data tabular terstruktur (structured tabular data) — seluruh fitur numerik

Tabel 1 Informasi Dataset

Dari tabel di atas dapat diketahui bahwa dataset yang digunakan memiliki jumlah data yang besar dengan fitur yang telah melalui proses transformasi menggunakan Principal Component Analysis (PCA). Hal ini menunjukkan bahwa dataset telah dipersiapkan untuk menjaga kerahasiaan data, sekaligus tetap memungkinkan penggunaan metode Machine Learning untuk analisis dan prediksi.

3.2 Deskripsi Fitur

Berikut merupakan deskripsi fitur yang terdapat dalam dataset Credit Card Fraud Detection yang digunakan dalam penelitian ini:

Fitur	Tipe Data	Keterangan	Missing	Peran
Time	Float	Detik yang berlalu sejak transaksi pertama dalam dataset	0%	Input
V1 – V14	Float	Komponen PCA hasil transformasi fitur asli yang dianonimkan untuk menjaga privasi nasabah	0%	Input (utama)
V15 – V28	Float	Komponen PCA lanjutan — makna asli tidak dipublikasikan oleh peneliti ULB	0%	Input (utama)
Amount	Float	Nominal transaksi dalam Euro (rentang: 0 – 25.691 Euro, distribusi sangat skewed)	0%	Input
Class	Integer	Label target: 0 = Transaksi Sah, 1 = Transaksi Fraud (Penipuan)	0%	Target Label

Tabel 2 Deskripsi Fitur Dataset

Dari tabel di atas dapat dilihat bahwa seluruh fitur dalam dataset bersifat numerik. Fitur V1 hingga V28 merupakan hasil transformasi Principal Component Analysis (PCA) yang bertujuan menjaga kerahasiaan data, sedangkan fitur Time dan Amount tetap dalam bentuk asli. Hal ini menunjukkan bahwa proses encoding tidak diperlukan, namun scaling tetap penting untuk menyamakan skala antar fitur.

3.3 Analisis Karakteristik Data

3.3.1 Distribusi Label (Target)

Berikut adalah distribusi kelas dalam dataset yang menunjukkan perbandingan antara transaksi fraud dan non-fraud:

Kelas	Jumlah	Persentase	Kesimpulan
Sah (0)	284.315	99,83%	Kelas mayoritas — mendominasi dataset secara ekstrem
Fraud (1)	492	0,17%	Kelas minoritas — sangat sedikit namun sangat kritis untuk dideteksi

Kelas	Jumlah	Persentase	Kesimpulan
Total	284.807	100%	Imbalance ratio ~578:1 — jauh lebih ekstrem dari kasus umum

Tabel 3 Distribusi Label

Kesimpulan: Ketidakseimbangan kelas bersifat sangat ekstrem (~99,83:0,17). Akurasi tidak dapat digunakan sebagai metrik utama — model yang selalu memprediksi 'Sah' pun akan mendapat akurasi 99,83%. Metrik utama adalah Recall, F1-Score, dan ROC-AUC.

Ketidakseimbangan kelas yang ekstrem ini merupakan tantangan utama dalam proses pembelajaran model, karena model cenderung bias terhadap kelas mayoritas. Oleh karena itu, diperlukan pendekatan khusus baik dalam preprocessing maupun pemilihan metrik evaluasi agar model tetap mampu mendeteksi kelas minoritas secara efektif

3.3.2 Potensi Bias Data

Dataset mencerminkan pola transaksi spesifik nasabah bank Eropa pada September 2013. Model yang dilatih mungkin tidak generalisasi sempurna ke pasar geografis lain atau periode waktu yang berbeda karena pola fraud bersifat dinamis (concept drift). Selain itu, fitur V1–V28 yang dianonimkan melalui PCA membatasi kemampuan interpretasi model secara bisnis, meskipun tidak mempengaruhi performa teknis.

3.3.3 Feature vs Target Relationship

Dalam dataset Credit Card Fraud Detection, seluruh variabel dapat dibagi menjadi dua kategori utama, yaitu fitur (input) dan target (output).

Fitur (input) terdiri dari variabel Time, Amount, serta V1 hingga V28 yang merupakan hasil transformasi Principal Component Analysis (PCA). Variabel-variabel tersebut digunakan sebagai representasi karakteristik transaksi kartu kredit. Sementara itu, target (output) dalam penelitian ini adalah variabel Class yang bersifat biner, yaitu:

- 0 = transaksi non-fraud
- 1 = transaksi fraud

Hubungan antara feature dan target dalam konteks ini adalah proses pemetaan pola transaksi terhadap kemungkinan terjadinya fraud. Model Machine Learning akan

mempelajari pola statistik dari fitur-fitur yang tersedia untuk membedakan transaksi fraud dan non-fraud.

Meskipun fitur hasil PCA tidak memiliki interpretasi langsung secara bisnis, model tetap dapat memanfaatkan pola distribusi data untuk melakukan klasifikasi dengan tingkat akurasi yang tinggi.

3.4 Identifikasi Tantangan Dataset

Berikut adalah identifikasi tantangan yang terdapat dalam dataset yang dapat mempengaruhi performa model Machine Learning:

Tantangan	Detail	Strategi Penanganan
Class Imbalance Ekstrem	Hanya 0,17% sampel fraud — model cenderung bias ke kelas mayoritas dan mengabaikan fraud	class_weight='balanced' pada algoritma; Stratified Sampling; evaluasi dengan Recall & ROC-AUC bukan Accuracy
Skala Fitur Bervariasi	Amount memiliki skala sangat berbeda (0–25.691) dibanding V1–V28 (z-score PCA); Time juga perlu disamakan	RobustScaler untuk Amount (tahan outlier); StandardScaler untuk Time
Fitur Anonim PCA	V1–V28 tidak memiliki nama semantik — interpretasi bisnis terbatas, tidak bisa dilakukan domain knowledge engineering	Fokus pada feature importance teknis; analisis distribusi statistik per fitur untuk memahami kontribusinya
Tidak Ada Missing Values	Semua 31 kolom lengkap (0% missing) — tidak perlu imputation	Tidak diperlukan penanganan khusus; langsung ke preprocessing scaling
Outlier pada Amount	Distribusi Amount sangat right-skewed dengan beberapa nilai ekstrem ratusan hingga puluhan ribu Euro	RobustScaler dan feature engineering log_amount untuk mereduksi dampak outlier

Tabel 4 Tantangan Dataset

Dari tabel di atas dapat disimpulkan bahwa terdapat beberapa tantangan utama dalam dataset, seperti ketidakseimbangan kelas, adanya noise, serta potensi kompleksitas

fitur akibat penggunaan PCA. Tantangan-tantangan ini perlu ditangani dengan strategi preprocessing dan pemodelan yang tepat.

Hasil analisis dataset ini menjadi dasar dalam perancangan pipeline Machine Learning yang akan dijelaskan pada bab berikutnya, termasuk strategi preprocessing, feature engineering, serta metode pemodelan yang digunakan.

BAB IV

PERANCANGAN PIPELINE MACHINE LEARNING

4.1 Gambaran Umum Pipeline

Pada tahap ini, dirancang pipeline Machine Learning yang menggambarkan alur proses pengolahan data secara menyeluruh, mulai dari data mentah hingga menghasilkan prediksi. Pipeline ini bertujuan untuk memastikan bahwa setiap tahapan dalam proses pembelajaran model dilakukan secara sistematis dan terstruktur.

Pipeline yang dirancang mencakup beberapa tahapan utama, yaitu eksplorasi data, preprocessing, feature engineering, pembagian data, pelatihan model, evaluasi, serta tahap deployment. Setiap tahapan memiliki peran penting dalam memastikan kualitas model yang dihasilkan.


Berikut adalah gambaran umum pipeline Machine Learning yang digunakan dalam penelitian ini:

NO	Tahap	Proses Utama	Output
1	Input Data	Muat CSV dari Kaggle	DataFrame 284.807 x 31
2	EDA	Eksplorasi distribusi, korelasi, imbalance, outlier	Pemahaman karakteristik data
3	Preprocessing	Scaling Amount & Time, handle imbalance	Dataset siap modeling
4	Feature Eng.	Tambah fitur hour_of_day dan log_amount	Fitur baru berbasis domain
5	Split Data	Train 80% / Test 20% dengan stratify	Train: 227.845 Test: 56.962
6	Training	Latih 2 model dengan class_weight=balanced	Model LR dan RF terlatih
7	Evaluasi	Recall, F1, ROC-AUC, Confusion Matrix	Laporan performa lengkap

NO	Tahap	Proses Utama	Output
8	Deployment	Simpan model, buat FastAPI endpoint	API inference real-time

Tabel 5 Gambaran Umum Pipeline Machine

Dari tabel di atas dapat dilihat bahwa pipeline Machine Learning dirancang secara terstruktur dari tahap awal hingga akhir. Setiap tahapan saling berkaitan dan berkontribusi dalam menghasilkan model yang optimal, mulai dari pengolahan data hingga proses deployment untuk penggunaan secara nyata.



Gambar 1 Pipeline Machine Learning

Gambar 1 menunjukkan alur lengkap pipeline Machine Learning yang digunakan dalam penelitian ini.

4.2 Tahap 1 – Exploratory Data Analysis (EDA)

Sebelum preprocessing, dilakukan eksplorasi data untuk memahami karakteristik dataset secara mendalam:

- Visualisasi distribusi label Class (bar chart) untuk memahami tingkat ketidakseimbangan kelas ekstrem (0,17% fraud).
- Distribusi Amount dan Time berdasarkan kelas — histogram terpisah untuk fraud vs non-fraud untuk melihat perbedaan pola.
- Heatmap korelasi antar fitur numerik untuk mendeteksi multikolinearitas antar komponen PCA.
- Boxplot distribusi V1–V28 per kelas untuk mengidentifikasi komponen PCA mana yang paling diskriminatif antara fraud dan sah.
- Analisis temporal: apakah fraud cenderung terjadi pada jam-jam tertentu dalam sehari?

4.3 Tahap 2 – Data Preprocessing

Tahap preprocessing merupakan langkah penting untuk memastikan data siap digunakan dalam proses pelatihan model. Proses ini mencakup normalisasi skala fitur, penanganan ketidakseimbangan data, serta pencegahan data leakage.

Berikut adalah langkah-langkah preprocessing yang diterapkan dalam penelitian ini:

Langkah	Aksi	Alasan
1. Scaling Amount	RobustScaler pada kolom Amount — menggunakan median dan IQR sebagai parameter scaling	Lebih robust terhadap outlier ekstrem pada Amount dibanding StandardScaler yang sensitif terhadap mean
2. Scaling Time	StandardScaler pada kolom Time untuk menyamakan skala dengan V1–V28	V1–V28 sudah dalam bentuk z-score hasil PCA; Time perlu disamakan agar tidak mendominasi model
3. Tidak Ada Drop Kolom	Semua 30 fitur input dipertahankan — tidak ada kolom ID atau teks yang tidak informatif	Dataset sudah bersih hasil PCA; berbeda dengan Titanic yang memiliki kolom teks dan ID tidak relevan

Langkah	Aksi	Alasan
4. Handle Imbalance	<code>class_weight='balanced'</code> pada kedua algoritma sebagai strategi utama penanganan imbalance	Memberikan bobot lebih tinggi pada kelas fraud saat training tanpa membuat data sintetis — lebih cepat dan aman
5. Scaler Fit Policy	Fit scaler HANYA pada <code>X_train</code> , kemudian transform ke <code>X_train</code> dan <code>X_test</code>	Mencegah data leakage — informasi statistik dari test set tidak boleh masuk ke proses training

Tabel 6 Tahapan Data Preprocessing

Dari tabel di atas dapat dilihat bahwa preprocessing dilakukan secara sistematis untuk memastikan kualitas data sebelum digunakan dalam proses pelatihan model, termasuk normalisasi fitur dan penanganan ketidakseimbangan data.

4.4 Tahap 3 – Feature Engineering

Feature engineering merupakan tahap penting dalam pipeline Machine Learning yang bertujuan untuk meningkatkan kualitas representasi data sehingga model dapat menangkap pola dengan lebih baik. Pada tahap ini dilakukan transformasi serta penambahan fitur baru yang relevan berdasarkan fitur yang sudah ada.

Dalam penelitian ini, feature engineering difokuskan pada pemanfaatan variabel yang tersedia seperti Time dan Amount untuk menghasilkan fitur tambahan yang lebih informatif. Proses ini diharapkan dapat membantu model dalam membedakan pola transaksi fraud dan non-fraud secara lebih efektif.

Berikut adalah langkah-langkah feature engineering yang diterapkan dalam penelitian ini:

Fitur Baru	Formula	Hipotesis
hour_of_day	<code>hour_of_day = (Time % 86400) // 3600</code> — mengekstrak jam dalam sehari dari waktu relatif (detik)	Penipuan kartu kredit mungkin cenderung terjadi pada jam-jam tertentu seperti dini hari ketika pengawasan lebih longgar dan korban tidak memantau transaksinya

Fitur Baru	Formula	Hipotesis
log_amount	$\log_amount = \log_{1p}(Amount)$ — transformasi logaritmik pada jumlah nominal transaksi	Mengurangi skewness ekstrem pada distribusi Amount dan membuat distribusi mendekati normal, bermanfaat khususnya untuk performa Logistic Regression yang sensitif terhadap distribusi fitur

Tabel 7 Feature Engineering yang Digun

Dari tabel di atas dapat dilihat bahwa feature engineering dilakukan secara selektif untuk meningkatkan kualitas informasi yang tersedia tanpa menambah kompleksitas model secara berlebihan.

4.5 Tahap 4 – Data Splitting Strategy

Data splitting merupakan tahap penting dalam pipeline Machine Learning yang bertujuan untuk membagi dataset menjadi data pelatihan dan data pengujian. Proses ini dilakukan untuk mengevaluasi kemampuan model dalam melakukan generalisasi terhadap data yang belum pernah dilihat sebelumnya.

Pada penelitian ini, teknik yang digunakan adalah stratified sampling, yang memastikan bahwa proporsi kelas fraud dan non-fraud tetap seimbang pada setiap subset data. Hal ini sangat penting mengingat dataset memiliki ketidakseimbangan kelas yang ekstrem.

Berikut adalah strategi pembagian data yang digunakan dalam penelitian ini:

Strategi	Detail
Train/Test Split	Rasio 80% training (227.845 data) dan 20% testing (56.962 data) menggunakan train_test_split dari scikit-learn dengan random_state=42 untuk hasil reproducible.
Stratified Sampling	Parameter stratify=y wajib digunakan agar proporsi kelas fraud (~0,17%) terjaga secara proporsional di kedua subset — tanpa stratifikasi, test set bisa mengandung sangat sedikit atau bahkan nol sampel fraud.

Strategi	Detail
Cross Validation	5-Fold Stratified Cross Validation pada training set. Stratifikasi di setiap fold krusial untuk dataset sangat imbalanced agar estimasi performa model stabil dan representatif.

Tabel 8 Strategi Data Splitting

Dari tabel di atas dapat dilihat bahwa pembagian data dilakukan secara sistematis untuk menjaga representasi distribusi kelas pada data training dan testing, sehingga model dapat dilatih dan dievaluasi secara lebih adil dan akurat.

4.6 Pipeline Workflow (End-toEnd)

Pipeline Machine Learning dalam penelitian ini dirancang secara end-to-end untuk mengolah data transaksi kartu kredit hingga menghasilkan prediksi klasifikasi secara akurat.

Proses dimulai dari input data mentah berupa dataset transaksi kartu kredit yang terdiri dari fitur Time, Amount, serta V1 hingga V28. Data kemudian melalui tahap preprocessing yang meliputi validasi data, scaling fitur numerik, serta penanganan ketidakseimbangan kelas menggunakan pendekatan seperti class weighting atau teknik sampling.

Selanjutnya, dilakukan feature engineering untuk meningkatkan kualitas fitur, seperti transformasi variabel Amount dan ekstraksi informasi tambahan dari variabel Time. Tahap ini bertujuan untuk membantu model dalam menangkap pola yang lebih kompleks.

Setelah itu, data dibagi menjadi data training dan data testing menggunakan metode stratified sampling agar distribusi kelas tetap terjaga. Model Machine Learning kemudian dilatih menggunakan data training dan dioptimalkan melalui proses hyperparameter tuning.

Tahap berikutnya adalah evaluasi model menggunakan data testing dengan metrik yang sesuai untuk kasus klasifikasi tidak seimbang, seperti Recall, Precision, F1-Score, dan ROC-AUC.

Output akhir dari pipeline ini adalah prediksi klasifikasi berupa Fraud atau Non-Fraud beserta nilai probabilitasnya. Model yang telah dilatih kemudian disimpan dan digunakan dalam tahap deployment untuk melakukan prediksi secara real-time melalui sistem berbasis API.

BAB V

STRATEGI PEMODELAN DAN EKSPERIMEN

5.1 Algoritma yang Digunakan

Dalam penelitian ini, digunakan dua algoritma Machine Learning untuk menyelesaikan permasalahan klasifikasi transaksi fraud, yaitu Logistic Regression dan Random Forest. Pemilihan kedua algoritma ini didasarkan pada pertimbangan keseimbangan antara kesederhanaan model, interpretabilitas, serta kemampuan dalam menangani kompleksitas data.

Logistic Regression digunakan sebagai baseline model karena merupakan algoritma yang sederhana, mudah diinterpretasikan, serta memiliki performa yang cukup baik pada permasalahan klasifikasi biner. Model ini berfungsi sebagai pembanding awal untuk mengevaluasi peningkatan performa yang dihasilkan oleh model yang lebih kompleks.

Sementara itu, Random Forest digunakan sebagai model utama karena kemampuannya dalam menangani hubungan non-linear antar fitur serta ketahanannya terhadap noise dan overfitting. Random Forest juga mampu memberikan informasi mengenai pentingnya fitur (feature importance), yang berguna dalam analisis lebih lanjut terhadap kontribusi masing-masing fitur dalam prediksi.

Dengan menggunakan kedua algoritma ini, diharapkan dapat diperoleh perbandingan performa yang jelas serta pemahaman yang lebih mendalam mengenai pendekatan terbaik dalam mendeteksi transaksi fraud pada dataset yang digunakan.

5.2 Logistic Regression (Baseline Model)

Logistic Regression adalah algoritma klasifikasi linear yang memodelkan probabilitas suatu sampel termasuk kelas tertentu menggunakan fungsi sigmoid. Model mempelajari bobot (koefisien) untuk setiap fitur melalui optimasi Maximum Likelihood Estimation, menghasilkan nilai probabilitas antara 0 dan 1 yang kemudian diklasifikasikan berdasarkan threshold (default: 0,5).

Aspek	Detail
Kelebihan	Sangat cepat dalam training dan inference — efisien untuk dataset 284.807 baris. Highly interpretable: koefisien menunjukkan

Aspek	Detail
	kontribusi tiap komponen PCA. Probabilitas terkalibrasi baik untuk penetapan threshold dinamis deteksi fraud.
Kekurangan	Hanya menangkap hubungan linear — mungkin underfitting jika interaksi non-linear antar komponen PCA dominan. Sensitif terhadap fitur yang tidak discaling dengan baik.
Peran dalam Eksperimen	Model baseline untuk mengukur seberapa besar peningkatan performa yang diberikan oleh Random Forest pada kasus fraud detection yang kompleks.

Tabel 9 Konfigurasi Logistic Regressio

Dari tabel di atas dapat dilihat bahwa parameter yang digunakan pada model Logistic Regression dipilih untuk memberikan keseimbangan antara performa model dan efisiensi komputasi. Penggunaan parameter seperti `class_weight = 'balanced'` bertujuan untuk menangani ketidakseimbangan kelas sehingga model dapat lebih sensitif terhadap deteksi transaksi fraud.

5.3 Random Forest Classifier (Model Utama)

Random Forest adalah algoritma ensemble learning yang membangun sejumlah besar Decision Tree secara paralel. Setiap tree dilatih pada subset data bootstrap dan setiap node split hanya mempertimbangkan subset fitur secara acak (feature bagging). Prediksi akhir ditentukan melalui voting mayoritas atau rata-rata probabilitas dari semua tree yang telah dibangun.

Aspek	Detail
Kelebihan	Akurasi tinggi pada berbagai jenis data. Robust terhadap outlier pada Amount. Mampu menangkap interaksi non-linear antar komponen PCA. Menghasilkan feature importance yang berguna untuk interpretasi komponen PCA mana yang paling diskriminatif.
Kekurangan	Lebih lambat dalam training dibanding Logistic Regression untuk dataset besar. Model lebih sulit diinterpretasikan secara individual (black box ensemble). Memerlukan lebih banyak memori.

Aspek	Detail
Peran dalam Eksperimen	Model utama dengan harapan menghasilkan Recall dan ROC-AUC tertinggi untuk kasus deteksi fraud kartu kredit.

Tabel 10 Konfigurasi Random Forest

Dari tabel di atas dapat dilihat bahwa parameter yang digunakan pada model Random Forest disesuaikan untuk meningkatkan kemampuan generalisasi serta mengurangi risiko overfitting. Penggunaan parameter seperti jumlah pohon ($n_estimators$) dan kedalaman pohon (max_depth) berperan penting dalam menentukan kompleksitas model.

5.4 Rancangan Eksperimen dan Hyperparameter Tuning

Berikut adalah parameter yang digunakan dalam proses pelatihan model Machine Learning:

Aspek	Detail
Metode Tuning	Grid Search CV (GridSearchCV dari scikit-learn) dengan 5-Fold Stratified Cross Validation. Exhaustive search pada semua kombinasi hyperparameter yang ditentukan.
Metrik Optimasi	Recall (scoring='recall') dipilih sebagai metrik optimasi utama karena dalam deteksi fraud, false negative (fraud tidak terdeteksi) jauh lebih merugikan secara finansial dibanding false positive.
Grid Logistic Regression	C: [0.001, 0.01, 0.1, 1, 10, 100] solver: [lbfgs, liblinear] class_weight: [balanced] max_iter: [1000]
Grid Random Forest	n_estimators: [100, 200, 300] max_depth: [None, 10, 20] min_samples_split: [2, 5] min_samples_leaf: [1, 2] class_weight: [balanced, balanced_subsample]

Tabel 11 Rancangan Eksperimen dan Hyper

Dari tabel di atas dapat dilihat bahwa pemilihan parameter dilakukan untuk mengoptimalkan performa model, baik dari segi akurasi maupun kemampuan generalisasi terhadap data baru.

5.5 Metrik Evaluasi

Pemilihan metrik evaluasi dalam kasus deteksi fraud tidak dapat hanya mengandalkan accuracy karena dataset memiliki ketidakseimbangan kelas yang sangat

ekstrem. Model yang selalu memprediksi kelas mayoritas dapat menghasilkan accuracy tinggi namun tidak berguna dalam mendeteksi fraud.

Oleh karena itu, metrik seperti Recall, Precision, F1-Score, dan ROC-AUC digunakan untuk memberikan gambaran performa model yang lebih komprehensif, terutama dalam mendeteksi kelas minoritas (fraud).

Berikut adalah metrik evaluasi yang digunakan dalam penelitian ini:

Metrik	Formula	Interpretasi	Prioritas
Recall	$TP / (TP+FN)$	Dari semua fraud nyata, berapa yang berhasil terdeteksi — metrik paling kritis untuk fraud detection	UTAMA
Precision	$TP / (TP+FP)$	Dari semua yang diprediksi fraud, berapa yang benar-benar fraud — relevan untuk meminimalkan false alarm	Penting
F1-Score	$2*(P*R)/(P+R)$	Harmonic mean Precision & Recall — keseimbangan deteksi dan akurasi prediksi fraud	UTAMA
ROC-AUC	Area Under ROC	Kemampuan model membedakan kelas di semua threshold — standar untuk imbalanced dataset	UTAMA
Average Precision	Area Under PR Curve	Lebih informatif dari ROC-AUC untuk dataset sangat imbalanced — sensitif terhadap kelas minoritas	UTAMA
Accuracy	$(TP+TN)/Total$	Tidak representatif untuk imbalanced data — hanya sebagai referensi sekunder	Sekunder
Confusion Matrix	TP, TN, FP, FN	Analisis detail berapa fraud yang lolos (FN) dan berapa transaksi sah yang salah ditandai (FP)	Diagnostik

Tabel 12 Metrik Evaluasi Model

Dari metrik di atas, Recall menjadi metrik yang paling penting karena berhubungan langsung dengan kemampuan model dalam mendeteksi transaksi fraud. Dalam konteks ini,

kesalahan berupa false negative (fraud yang tidak terdeteksi) memiliki dampak yang lebih besar dibandingkan false positive.

5.6 Rencana Analisis Overfitting dan Bias-Variance Tradeoff

Berikut adalah rencana analisis yang digunakan untuk mengidentifikasi potensi overfitting dan underfitting pada model, serta mengevaluasi keseimbangan antara bias dan variance dalam proses pembelajaran Machine Learning:

Analisis	Detail
Deteksi Overfitting	Membandingkan training Recall vs rata-rata CV Recall. Jika selisih > 10% maka overfitting — solusi: batasi max_depth, tingkatkan min_samples_split pada RF, atau naikkan C regularization pada LR.
Deteksi Underfitting	Jika training Recall dan CV Recall keduanya rendah (< 70%), model underfitting — solusi: tambah fitur baru, gunakan model lebih kompleks, atau kurangi regularisasi.
Bias-Variance LR	Cenderung high bias / low variance — asumsi linearitas dapat menyebabkan model tidak mampu menangkap pola fraud yang kompleks (underfitting), namun prediksi antar fold konsisten.
Bias-Variance RF	Cenderung low bias / high variance per tree, namun averaging dari banyak tree mereduksi variance keseluruhan. Hyperparameter max_depth dan min_samples mengontrol keseimbangan ini.
Threshold Analysis	Analisis Precision-Recall di berbagai threshold (0,1–0,9) untuk menentukan threshold optimal. Threshold lebih rendah meningkatkan Recall (lebih banyak fraud terdeteksi) dengan konsekuensi lebih banyak false alarm.

Tabel 13 Analisis Overfitting dan Bias- Variance

Dari tabel di atas dapat disimpulkan bahwa analisis overfitting dan bias-variance tradeoff dilakukan secara sistematis untuk memastikan model tidak hanya memiliki performa yang baik pada data training, tetapi juga mampu melakukan generalisasi dengan baik pada data baru.

Strategi pemodelan yang dirancang dalam penelitian ini bertujuan untuk menghasilkan model dengan performa optimal dalam mendeteksi fraud, khususnya dengan

memaksimalkan nilai recall. Pemilihan algoritma, metode tuning, serta metrik evaluasi dilakukan secara sistematis untuk memastikan hasil yang robust dan dapat diandalkan.

BAB VI

RENCANA DEPLOYMENT MODEL

6.1 Bentuk Deployment

Berikut adalah bentuk deployment yang dipilih dalam penelitian ini beserta karakteristik dan alasan pemilihannya:

Aspek	Detail
Platform Terpilih	FastAPI REST API — framework Python modern berkinerja tinggi, ideal untuk deployment model ML sebagai layanan deteksi fraud yang dapat diintegrasikan ke sistem pembayaran secara real-time.
Alasan Pemilihan	(1) Mendukung async request untuk volume transaksi besar. (2) Dokumentasi API otomatis via Swagger UI. (3) Validasi input otomatis via Pydantic. (4) Production-ready dan mudah di-deploy ke cloud (AWS/GCP). (5) Latensi sangat rendah untuk inference real-time.
Alternatif	Streamlit dapat digunakan sebagai dashboard monitoring fraud internal untuk tim analis — menampilkan statistik fraud real-time dan feature importance. Arsitektur ideal: FastAPI (backend API) + Streamlit (frontend monitoring dashboard).

Tabel 14 Bentuk Deployment Model

Dari tabel di atas dapat disimpulkan bahwa deployment berbasis API menggunakan FastAPI dipilih karena kemudahan integrasi, performa yang baik, serta fleksibilitas dalam pengembangan sistem berbasis Machine Learning.

6.2 Alur Inference: Input → Model → Output

Berikut adalah alur proses inference yang menggambarkan bagaimana data input diproses oleh sistem hingga menghasilkan output berupa prediksi. Proses ini mencakup tahapan mulai dari penerimaan data transaksi, preprocessing yang memastikan kesesuaian format data, hingga penggunaan model Machine Learning untuk menghasilkan prediksi klasifikasi beserta probabilitasnya.


NO	Tahap	Detail
1	POST Request	Sistem pembayaran mengirim HTTP POST ke /predict dengan JSON body berisi: time, amount, v1–v28 (30 field wajib)
2	Validasi Input	FastAPI + Pydantic memvalidasi tipe data dan kelengkapan semua 30 fitur secara otomatis — request tidak lengkap ditolak dengan error 422
3	Preprocessing	Input dikonversi ke DataFrame pandas, diterapkan feature engineering (hour_of_day, log_amount), kemudian di-transform menggunakan scaler_amount.pkl dan scaler_time.pkl
4	Load Model	Model rf_model.pkl dimuat SEKALI saat startup aplikasi, bukan per-request — untuk efisiensi latensi pada volume transaksi tinggi
5	Prediksi	model.predict(X) menghasilkan label biner (0/1) dan model.predict_proba(X) menghasilkan probabilitas fraud [0.0–1.0]
6	Response Output	API mengembalikan JSON: {is_fraud: true/false, fraud_probability: 0.87, risk_level: HIGH/MEDIUM/LOW, processing_time_ms: 12}

Tabel 15 Alur Proses Inference Sistem

Format Input: JSON body — {"time": 406.0, "amount": 149.62, "v1": -1.359, "v2": -0.073, ..., "v28": -0.021}

Format Output: JSON response — {"is_fraud": false, "fraud_probability": 0.023, "risk_level": "LOW", "processing_time_ms": 8}.

Dari tabel di atas dapat dilihat bahwa proses inference berjalan secara terstruktur, dimulai dari input data transaksi, dilanjutkan dengan preprocessing, hingga menghasilkan output berupa klasifikasi fraud atau non-fraud beserta nilai probabilitasnya.



Gambar 2 Diagram Alur Inference

Gambar 2 menunjukkan alur proses inference dari input data hingga menghasilkan prediksi.

6.3 Struktur Sistem dan Arsitektur Sederhana

Struktur sistem dalam penelitian ini dirancang secara modular untuk memisahkan komponen utama seperti proses preprocessing, model Machine Learning, serta proses inference. Pendekatan modular ini bertujuan untuk meningkatkan fleksibilitas, kemudahan pengelolaan, serta memungkinkan pengembangan sistem lebih lanjut di masa depan.

Setiap komponen memiliki peran yang spesifik, mulai dari penerimaan input data, proses transformasi data agar sesuai dengan format yang dibutuhkan model, hingga menghasilkan output berupa prediksi. Dengan arsitektur yang terstruktur, sistem diharapkan dapat berjalan secara efisien dan mudah diintegrasikan ke dalam aplikasi berbasis API.

File / Folder	Fungsi
app.py	Script utama FastAPI — mendefinisikan endpoint POST /predict dan GET /health dengan dokumentasi Swagger otomatis

File / Folder	Fungsi
train.py	Script training model — preprocessing, GridSearchCV tuning, evaluasi, menyimpan model dan scaler
model/rf_model.pkl	Model Random Forest terbaik hasil GridSearchCV (disimpan via joblib setelah training)
model/scaler_amount.pkl	RobustScaler yang di-fit pada Amount dari X_train — wajib disimpan untuk konsistensi inference
model/scaler_time.pkl	StandardScaler yang di-fit pada Time dari X_train — mencegah data leakage saat produksi
utils/preprocessing.py	Fungsi feature engineering dan scaling yang digunakan bersama oleh train.py dan app.py
schemas/request.py	Pydantic model TransactionInput — validasi otomatis 30 fitur input API
data/creditcard.csv	Dataset asli dari Kaggle (tidak di-deploy, hanya untuk training lokal)
requirements.txt	fastapi, uvicorn, scikit-learn, pandas, joblib, pydantic, imbalanced-learn

Tabel 16 Struktur dan Fungsi Komponen Sistem

Cara Simpan Model: Setelah training — `joblib.dump(best_rf, 'model/rf_model.pkl')`, `joblib.dump(scaler_amount, 'model/scaler_amount.pkl')`, `joblib.dump(scaler_time, 'model/scaler_time.pkl')`. Penting: semua scaler harus di-fit hanya pada X_train untuk mencegah data leakage saat inference produksi.

BAB VII

TIMELINE Pengerjaan Proyek

Berikut adalah rencana timeline pengerjaan proyek yang disusun secara sistematis:

Minggu	Fase	Kegiatan Utama	Output
Minggu 1	Persiapan & EDA	Download dataset, eksplorasi distribusi kelas, analisis imbalance, pola Amount & Time, visualisasi V1–V28 per kelas	Notebook EDA, laporan karakteristik data
Minggu 2	Preprocessing	RobustScaler Amount, StandardScaler Time, feature engineering hour_of_day & log_amount, stratified train/test split	Dataset bersih siap modeling
Minggu 3	Modeling Baseline	Implementasi Logistic Regression dengan class_weight='balanced', training, evaluasi awal Confusion Matrix dan ROC-AUC	Baseline model + metrik awal
Minggu 4	Modeling Utama	Implementasi Random Forest, Grid Search CV dengan scoring Recall, 5-Fold Stratified CV, threshold analysis	Model RF teroptimasi
Minggu 5	Evaluasi & Analisis	Perbandingan performa kedua model, PR curve, feature importance, analisis overfitting, threshold optimal	Laporan evaluasi lengkap
Minggu 6	Deployment	Implementasi FastAPI endpoint, Pydantic schema, testing inference, dokumentasi API Swagger	API FastAPI berjalan
Minggu 7	Finalisasi	Penyusunan laporan akhir, review kode, dokumentasi teknis, persiapan presentasi UAS	Laporan & kode final

Tabel 17 Timeline Pengerjaan Proyek

Dari tabel di atas dapat dilihat bahwa setiap tahapan proyek telah direncanakan secara terstruktur, mulai dari pengumpulan data hingga deployment model.

BAB VIII

KESIMPULAN

Berdasarkan rancangan yang telah disusun, penelitian ini bertujuan untuk membangun sistem deteksi fraud transaksi kartu kredit menggunakan pendekatan Machine Learning. Dataset yang digunakan memiliki karakteristik ketidakseimbangan kelas yang tinggi sehingga memerlukan strategi preprocessing dan evaluasi yang tepat.

Model yang digunakan dalam penelitian ini adalah Logistic Regression dan Random Forest yang akan dibandingkan performanya menggunakan metrik evaluasi seperti Recall, Precision, F1-Score, dan ROC-AUC.

Selain itu, sistem deployment dirancang menggunakan FastAPI agar model dapat digunakan untuk melakukan prediksi secara real-time. Dengan rancangan yang telah dibuat, diharapkan sistem ini mampu membantu proses deteksi fraud secara lebih efektif dan efisien.

DAFTAR PUSTAKA

- Breiman, L. (2001). Random Forests. *Machine Learning*, 5–32.
- Chawla, N. V. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research (JAIR)*, 321–357.
- Dal Pozzolo, A. C. (2015). Calibrating Probability with Undersampling for Unbalanced Classification. *IEEE Symposium Series on Computational Intelligence (SSCI)*, (pp. 159–166).
- FastAPI. (2023). *FastAPI Documentation*. Retrieved from <https://fastapi.tiangolo.com/>
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.
- Jurgovsky, J. J.-E.-G. (2018). Sequence Classification for Credit-Card Fraud Detection. *Expert Systems with Applications*.
- Lemaître, G. N. (2017). Imbalanced-learn: A Python Toolbox. *Journal of Machine Learning Research (JMLR)*, 1-5.
- Pedregosa, F. e. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research (JMLR)*, 2825–2830.
- ULB, M. L.—U. (2018). *Credit Card Fraud Detection — Kaggle*. Retrieved from Kaggle: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>