

**PROPOSAL PREDIKSI KESELAMATAN
PENUMPANG TITANIC MENGGUNAKAN MACHINE
LEARNING**

Dosen Pengampu :
Abu Salam M.Kom



Disusun oleh :

Bungalunna Nashuha Camelia - A11.2024.15611

**PROGRAM STUDI TEKNIK INFORMATIKA
UNIVERSITAS DIAN NUSWANTORO SEMARANG
TAHUN 2026**

DAFTAR ISI

JUDUL	1
DAFTAR ISI.....	2
DAFTAR TABEL.....	4
BAB I PENDAHULUAN.....	5
1.1 Latar Belakang	5
1.2 Mengapa Machine Learning?.....	5
BAB II PERUMUSAN MASALAH	7
2.1 Identifikasi Masalah	7
2.2 Tujuan Proyek	7
2.3 Hipotesis Awal	8
BAB III ANALISIS DATASET DAN REPRESENTASI DATA	9
3.1 Informasi Dataset	9
3.2 Deskripsi Fitur.....	9
3.3 Analisis Karakteristik Data	10
3.3.1 Distribusi Label (Target).....	10
3.3.2 Potensi Bias Data	10
3.3.3 Identifikasi Tantangan Dataset.....	10
BAB IV PERANCANGAN PIPELINE MACHINE LEARNING.....	12
4.1 Gambaran Umum Pipeline	12
4.2 Tahap 1 – Exploratory Data Analysis (EDA)	12
4.3 Tahap 2 – Data Preprocessing.....	13
4.4 Tahap 3 – Feature Engineering	14
4.5 Tahap 4 – Data Splitting	14

BAB V STRATEGI PEMODELAN DAN EKSPERIMEN.....	16
5.1 Algoritma yang Digunakan.....	16
5.1.1 Gaussian Naive Bayes (Baseline Model).....	16
5.1.2 Random Forest Classifier (Model Utama)	17
5.2 Hyperparameter Tuning	17
5.3 Metrik Evaluasi	18
5.4 Rencana Analisis Overfitting dan Bias-Variance Tradeoff	19
BAB VI RENCANA DEPLOYMENT MODEL.....	20
6.1 Bentuk Deployment	20
6.2 Alur Inference: Input - Proses – Output.....	20
6.3 Arsitektur Sistem dan Struktur File	21
BAB VII TIMELINE Pengerjaan Proyek	23
DAFTAR REFERENSI	24

DAFTAR TABEL

Tabel 1. Mengapa Machine Learning?.....	6
Tabel 2. Tujuan Proyek	8
Tabel 3. Hipotesis Awal	8
Tabel 4. Informasi Dataset	9
Tabel 5. Deskripsi Fitur.....	10
Tabel 6. Distribusi Label (Target).....	10
Tabel 7. Identifikasi Tantangan Dataset.....	11
Tabel 8. Gambaran Umum Pipeline.....	12
Tabel 9. Tahap 2 - Data Preprocessing	13
Tabel 10. Tahap 3 - Feature Engineering.....	14
Tabel 11. Tahap 4 - Data Splitting	15
Tabel 12. Gaussian Naive Bayes (Baseline Model).....	16
Tabel 13. Random Forest Classifier (Model Utama).....	17
Tabel 14. Hyperparameter Tuning	18
Tabel 15. Metrik Evaluasi	19
Tabel 16. Rencana Analisis Overfitting dan Bias-Variance Tradeoff	19
Tabel 17. Bentuk Deployment	20
Tabel 18. Alur Inference	20
Tabel 19. Input-Proses-Output	21
Tabel 20. Arsitektur Sistem dan Struktur File	22
Tabel 21. Timeline Pengerjaan Proyek	23

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pada tanggal 14-15 April 1912, kapal pesiar mewah RMS Titanic tenggelam di Samudra Atlantik Utara setelah menabrak gunung es dalam pelayaran perdananya dari Southampton, Inggris menuju New York, Amerika Serikat. Dari total 2.224 penumpang dan awak kapal, hanya sekitar 710 orang yang berhasil selamat, sementara lebih dari 1.500 orang meninggal dunia. Tragedi ini menjadi salah satu bencana maritim paling mematikan dalam sejarah manusia.

Data historis dari kejadian tersebut telah terdokumentasi dengan baik dan tersedia secara publik. Analisis data menunjukkan bahwa peluang keselamatan seorang penumpang tidak bersifat acak, melainkan dipengaruhi secara signifikan oleh beberapa faktor demografis dan sosial-ekonomi. Penumpang wanita, anak-anak, dan mereka yang menempati kelas tiket lebih tinggi terbukti memiliki tingkat keselamatan yang jauh lebih tinggi dibandingkan kelompok lainnya.

Perkembangan Machine Learning membuka peluang untuk membangun model prediktif yang mampu mengidentifikasi pola-pola tersembunyi dari data historis Titanic. Dengan menggunakan algoritma klasifikasi, model dapat dilatih untuk memprediksi apakah seorang penumpang akan selamat atau tidak berdasarkan karakteristik yang dimilikinya. Kemampuan ini tidak hanya bernilai historis, tetapi juga relevan sebagai studi kasus pembelajaran untuk memahami konsep klasifikasi biner, feature engineering, dan evaluasi model dalam Machine Learning.

1.2 Mengapa Machine Learning?

Pendekatan Rule-Based	Sistem berbasis aturan (rule-based) seperti 'jika perempuan maka selamat' atau 'jika kelas 1 maka selamat' hanya menangkap
-----------------------	--

	pola sederhana satu dimensi. Pendekatan ini tidak mampu mempertimbangkan interaksi kompleks antar beberapa fitur secara bersamaan, tidak generalisasi dengan baik, dan sulit dikembangkan seiring bertambahnya jumlah aturan.
Pendekatan Machine Learning	Model ML mempelajari pola secara otomatis dari data pelatihan, mampu menangkap hubungan non-linear dan interaksi kompleks antar fitur (contoh: kombinasi usia muda + kelas 3 + laki-laki), menghasilkan probabilitas prediksi yang informatif, dan dapat digeneralisasi ke data baru yang belum pernah dilihat sebelumnya.
Keunggulan Machine Learning untuk Kasus Ini	Dataset Titanic memiliki banyak fitur dengan interaksi yang tidak trivial. Sebagai contoh, usia berinteraksi dengan jenis kelamin (anak laki-laki mungkin diselamatkan seperti wanita), dan harga tiket berkorelasi dengan kelas sosial yang mempengaruhi akses ke sekoci. Pola kompleks seperti ini hanya dapat ditangkap secara optimal oleh model ML.

Tabel 1. Mengapa Machine Learning?

BAB II

PERUMUSAN MASALAH

2.1 Identifikasi Masalah

Berdasarkan latar belakang yang telah diuraikan, terdapat beberapa permasalahan yang ingin diselesaikan dalam proyek ini:

- Bagaimana membangun model Machine Learning yang akurat untuk memprediksi keselamatan penumpang Titanic berdasarkan fitur demografis dan informasi tiket?
- Algoritma klasifikasi mana yang memberikan performa terbaik untuk kasus prediksi keselamatan penumpang Titanic — Gaussian Naive Bayes atau Random Forest?
- Fitur apa saja yang paling berpengaruh dalam menentukan keselamatan penumpang Titanic menurut model Machine Learning?
- Bagaimana menangani tantangan data seperti missing values, imbalanced class, dan outlier agar model dapat belajar secara optimal?

2.2 Tujuan Proyek

Tujuan Utama	Membangun model klasifikasi biner yang mampu memprediksi apakah seorang penumpang Titanic selamat (1) atau tidak selamat (0) berdasarkan fitur-fitur yang tersedia dalam dataset.
Tujuan Komparatif	Membandingkan performa dua algoritma Machine Learning (Gaussian Naive Bayes dan Random Forest) berdasarkan metrik akurasi, presisi, recall, F1-Score, dan ROC-AUC.
Tujuan analitik	Mengidentifikasi fitur-fitur yang paling berpengaruh (feature importance) terhadap

	prediksi keselamatan penumpang menggunakan Random Forest.
Tujuan Deployment	Merancang dan mendeskripsikan sistem deployment sederhana berbasis Streamlit agar model dapat digunakan secara interaktif oleh pengguna umum.

Tabel 2. Tujuan Proyek

2.3 Hipotesis Awal

Hipotesis 1	Random Forest akan menghasilkan akurasi dan F1-Score lebih tinggi dibandingkan Gaussian Naive Bayes karena kemampuannya menangkap interaksi non-linear antar fitur seperti kombinasi Sex, Pclass, dan Age secara bersamaan.
Hipotesis 2	Fitur Sex (jenis kelamin) dan Pclass (kelas tiket) akan menjadi dua prediktor terkuat keselamatan penumpang, konsisten dengan fakta historis bahwa wanita dan penumpang kelas 1 mendapat prioritas evakuasi.
Hipotesis 3	Model akan mencapai akurasi di atas 80% dan F1-Score minimal 0.78 pada data uji setelah dilakukan preprocessing yang tepat termasuk penanganan missing values dan encoding fitur kategorikal.
Hipotesis 4	Feature engineering berupa penambahan fitur FamilySize dan IsAlone akan meningkatkan performa model karena status keberadaan keluarga di kapal mempengaruhi keputusan evakuasi.

Tabel 3. Hipotesis Awal

BAB III

ANALISIS DATASET DAN REPRESENTASI DATA

3.1 Informasi Dataset

Nama Dataset	Titanic Dataset
Sumber	Kaggle-Platform dataset publik terkurasi
URL	https://www.kaggle.com/datasets/yasserh/titanic-dataset
Pembuat	YasserH (diunggah ke Kaggle, 2021)
Lisensi	CC0 — Public Domain (bebas digunakan untuk riset & pendidikan)
Format File	CSV (Comma-Separated Values)
Dimensi Data	891 baris (penumpang) x 12 kolom (fitur)
Jenis Data	Data tabular terstruktur (structured tabular data)

Tabel 4. Informasi Dataset

3.2 Deskripsi Fitur

PassangerId	Integer	ID unik tiap penumpang	0%	Dihapus
Survived	Integer	0=tidak selamat, 1=selamat	0%	Target Label
Pclass	Integer	Kelas tiket: 1 (atas), 2 (menengah), 3 (bawah)	0%	Input
Name	String	Nama lengkap penumpang	0%	Dihapus
Sex	Kategorikal	Jenis kelamin: male / female	0%	Input
Age	Float	Usia dalam tahun	19.9%	Input
SibSp	Integer	Jumlah saudara/pasangan di kapal	0%	Input
Parch	Integer	Jumlah orang tua/anak di kapal	0%	Input
Ticket	String	Nomor tiket (tidak terstruktur)	0%	Dihapus
Fare	Float	Harga tiket yang dibayarkan	0%	Input
Cabin	String	Nomor kabin	77.1%	Dihapus

Embarked	Kategorikal	Pelabuhan: C=Cherbourg, Q=Queenstown, S=Southampton	0.2%	Input
----------	-------------	--	------	-------

Tabel 5. Deskripsi Fitur

3.3 Analisis Karakteristik Data

3.3.1 Distribusi Label (Target)

Tidak Selamat (0)	549 penumpang — 61.6% dari total data.
Selamat (1)	342 penumpang — 38.4% dari total data.
Kesimpulan	Terdapat ketidakseimbangan kelas moderat (~60:40). Tidak terlalu parah namun perlu diperhatikan dalam evaluasi — gunakan F1-Score dan ROC-AUC sebagai metrik utama, bukan hanya akurasi.

Tabel 6. Distribusi Label (Target)

3.3.2 Potensi Bias Data

Dataset mencerminkan kebijakan evakuasi era 1912 yang menerapkan prinsip 'women and children first'. Akibatnya, model yang dilatih pada data ini akan secara alami sangat bergantung pada fitur Sex dan Age. Ini bukan bias teknis dalam pengumpulan data, melainkan refleksi dari kondisi historis yang nyata. Model yang dihasilkan bersifat deskriptif terhadap kejadian historis tersebut, bukan preskriptif untuk situasi masa kini.

3.3.3 Identifikasi Tantangan Dataset

Missing Values	Age: 177 baris kosong (19.9%) — akan diisi dengan median. Cabin: 687 baris kosong (77.1%) — kolom akan dihapus sepenuhnya. Embarked: 2 baris kosong
----------------	---

	(0.2%) — akan diisi dengan modus yaitu S (Southampton).
Outlier / Noise	Kolom Fare memiliki distribusi sangat skewed dengan beberapa nilai ekstrem (penumpang kelas 1 membayar ratusan pound). Akan ditangani dengan StandardScaler yang meminimalkan dampak outlier pada proses training.
Fitur Tidak Relevan	Kolom PassengerId (ID unik), Name (nama teks bebas), Ticket (nomor tidak terstruktur), dan Cabin (77% kosong) tidak memiliki nilai prediktif langsung dan akan dihapus dari dataset sebelum modeling.
High Cardinality	Tidak ada masalah high cardinality setelah penghapusan kolom Name dan Ticket. Fitur kategorikal yang tersisa (Sex, Embarked) memiliki jumlah kategori kecil dan mudah di-encode.

Tabel 7. Identifikasi Tantangan Dataset

BAB IV

PERANCANGAN PIPELINE MACHINE LEARNING

4.1 Gambaran Umum Pipeline

1. Input Data	Muat CSV dari Kaggle.
2. EDA	Eksplorasi & visualisasi.
3. Preprocessing	Cleaning, encoding, scaling.
4. Feature Engineering	Tambah fitur baru.
5. Split Data	Train 80% / Test 20%.
6. Training	Latih 2 model ML.
7. Evaluasi	Hitung metrik & CM.
8. Deployoment	Simpan model, buat app.

Tabel 8. Gambaran Umum Pipeline

4.2 Tahap 1 – Exploratory Data Analysis (EDA)

Sebelum preprocessing, dilakukan eksplorasi data untuk memahami karakteristik dataset secara mendalam:

- Visualisasi distribusi label Survived (bar chart) untuk memahami proporsi kelas.
- Analisis survival rate berdasarkan Sex — diperkirakan wanita memiliki tingkat keselamatan jauh lebih tinggi.
- Analisis survival rate berdasarkan Pclass — diperkirakan penumpang kelas 1 memiliki tingkat keselamatan tertinggi.
- Distribusi usia (histogram Age) untuk memahami pola usia penumpang dan nilai yang hilang.
- Heatmap korelasi antar fitur numerik untuk mendeteksi multikolinearitas.
- Boxplot Fare untuk mengidentifikasi sebaran nilai dan outlier.

4.3 Tahap 2 – Data Preprocessing

Langkah 1: Hapus Kolom	Menghapus kolom PassengerId, Name, Ticket, dan Cabin karena tidak relevan atau terlalu banyak nilai kosong.
Langkah 2: Handle Missing Age	Mengisi nilai kosong pada kolom Age dengan nilai median (lebih robust terhadap outlier dibanding mean). median dipilih karena distribusi Age cenderung skewed.
Langkah 3: Handle Missing Embarked	Mengisi 2 nilai kosong pada Embarked dengan nilai modus yaitu 'S' (Southampton) karena merupakan nilai paling sering muncul.
Langkah 4: Encoding Sex	Label Encoding pada kolom Sex: male = 0, female = 1. Dipilih Label Encoding karena hanya ada 2 kategori (biner).
Langkah 5: Encoding Embarked	One-Hot Encoding pada kolom Embarked menghasilkan 3 kolom baru: Embarked_C, Embarked_Q, Embarked_S. Menggunakan drop_first=True untuk menghindari dummy variable trap (multikolinearitas).
Langkah 6: Feature Scaling	Menerapkan StandardScaler pada fitur numerik kontinu (Age, Fare, SibSp, Parch) untuk menormalkan skala nilai menjadi mean=0 dan std=1. Scaler di-fit hanya pada training data dan di-transform ke test data untuk mencegah data leakage.

Tabel 9. Tahap 2 - Data Preprocessing

4.4 Tahap 3 – Feature Engineering

FamilySize	Menambahkan fitur baru: FamilySize = SibSp + Parch + 1. Nilai +1 memperhitungkan penumpang itu sendiri. Fitur ini merepresentasikan total anggota keluarga di kapal dan diharapkan lebih informatif dibanding SibSp dan Parch secara terpisah.
IsAlone	Fitur biner baru: IsAlone = 1 jika FamilySize = 1 (bepergian sendiri), IsAlone = 0 jika bersama keluarga. Hipotesis: penumpang yang bepergian sendiri mungkin memiliki pola keselamatan berbeda.
Title (Opsional)	Mengekstrak gelar (Mr., Mrs., Miss., Master., dll.) dari kolom Name sebelum dihapus. Gelar dapat menjadi proxy untuk usia dan status sosial yang informatif. Ini bersifat opsional dan akan diuji dampaknya pada performa model.

Tabel 10. Tahap 3 - Feature Engineering

4.5 Tahap 4 – Data Splitting

Metode Split	Train/Test Split dengan rasio 80% training (712 data) dan 20% testing (179 data) menggunakan fungsi train_test_split dari library scikit-learn.
--------------	---

Stratified Sampling	Parameter stratify=y digunakan agar proporsi kelas Survived (~60:40) terjaga di kedua subset data, sehingga model dilatih dan diuji pada distribusi kelas yang representatif.
Random State	random_state=42 ditetapkan untuk memastikan hasil pembagian data dapat direproduksi (reproducible) di setiap kali percobaan.
Cross Validation	5-Fold Stratified Cross Validation diterapkan pada training set untuk mendapatkan estimasi performa yang lebih stabil dan mendeteksi overfitting sedini mungkin.

Tabel 11. Tahap 4 - Data Splitting

BAB V

STRATEGI PEMODELAN DAN EKSPERIMEN

5.1 Algoritma yang Digunakan

5.1.1 Gaussian Naive Bayes (Baseline Model)

Gaussian Naive Bayes adalah algoritma probabilistik yang menerapkan Teorema Bayes dengan asumsi bahwa setiap fitur bersifat kondisional independen terhadap kelas target, dan bahwa setiap fitur berdistribusi Gaussian (distribusi normal). Model menghitung probabilitas posterior untuk setiap kelas berdasarkan probabilitas prior dan likelihood, kemudian memilih kelas dengan probabilitas posterior tertinggi sebagai prediksi.

Kelebihan	Sangat cepat dalam training dan inference. Bekerja baik dengan dataset kecil. Tidak memerlukan banyak hyperparameter. Menghasilkan probabilitas prediksi. Cocok untuk fitur numerik kontinu seperti Age dan Fare.
Kekurangan	Asumsi independensi fitur jarang terpenuhi sepenuhnya di data nyata. Tidak dapat menangkap interaksi antar fitur. Performa lebih rendah dibanding model ensemble pada data kompleks.
Peran dalam Eksperimen	Digunakan sebagai model baseline untuk membandingkan seberapa besar peningkatan yang diberikan oleh Random Forest.

Tabel 12. Gaussian Naive Bayes (Baseline Model)

5.1.2 Random Forest Classifier (Model Utama)

Random Forest adalah algoritma ensemble learning yang membangun sejumlah besar Decision Tree secara paralel. Setiap tree dilatih pada subset data yang dipilih secara acak dengan penggantian (bootstrap sampling), dan setiap split node hanya mempertimbangkan subset fitur secara acak (feature bagging). Prediksi akhir ditentukan melalui voting mayoritas dari semua tree yang telah dibangun.

Kelebihan	Akurasi tinggi pada berbagai jenis data. Robust terhadap outlier dan missing values. Mampu menangkap interaksi non-linear antar fitur. Menghasilkan feature importance yang berguna untuk interpretasi. Tidak sensitif terhadap scaling fitur.
Kekurangan	Lebih lambat dalam training dibanding Naive Bayes. Model kurang interpretatif secara langsung (black box). Memerlukan lebih banyak memori dan komputasi.
Peran dalam Eksperimen	Digunakan sebagai model utama dengan harapan menghasilkan performa terbaik pada dataset Titanic

Tabel 13. Random Forest Classifier (Model Utama)

5.2 Hyperparameter Tuning

Metode	Grid Search CV dengan 5-Fold Stratified Cross Validation menggunakan GridSearchCV dari scikit-learn. Metode ini secara exhaustive mencoba semua
--------	---

	kombinasi hyperparameter yang ditentukan dan memilih kombinasi terbaik berdasarkan F1-Score.
Metrik Optimasi	F1-Score (scoring='f1') dipilih sebagai metrik optimasi hyperparameter karena dataset memiliki ketidakseimbangan kelas moderat, sehingga F1-Score lebih representatif dibanding accuracy.
Grid Naive Bayes	var_smoothing: [1e-9, 1e-8, 1e-7, 1e-6, 1e-5].
Grid Random Forest	n_estimators: [100, 200, 300] max_depth: [None, 5, 10, 15] min_samples_split: [2, 5, 10] min_samples_leaf: [1, 2, 4] max_features: [sqrt, log2].

Tabel 14. Hyperparameter Tuning

5.3 Metrik Evaluasi

Metrik	Formula	Interpretasi	Prioritas
Accuracy	$(TP+TN)/(TP+TN+FP+FN)$	Proporsi prediksi benar dari seluruh data.	Sekunder
Precision	$TP/(TP+FP)$	Dari semua yang diprediksi selamat, berapa yang benar selamat.	Penting
Recall	$TP/(TP+FN)$	Dari semua yang benar selamat, berapa yang berhasil dideteksi.	Penting
F1-Score	$2*(P*R)/(P+R)$	Harmonic mean Precision & Recall — keseimbangan keduanya.	Utama
ROC-AUC	Area Under ROC	Kemampuan model membedakan kelas di semua threshold.	Utama

Confusion Matrix	TP,TN,FP,FN	Analisis detail jenis kesalahan prediksi.	Diagnostik
------------------	-------------	---	------------

Tabel 15. Metrik Evaluasi

5.4 Rencana Analisis Overfitting dan Bias-Variance Tradeoff

Deteksi Overfitting	Membandingkan training accuracy vs rata-rata CV accuracy. Jika selisih $> 5\%$ maka model dianggap overfitting. Solusi: batasi max_depth, tingkatkan min_samples_split, atau kurangi n_estimators pada Random Forest.
Deteksi Underfitting	Jika training accuracy dan CV accuracy keduanya rendah ($< 75\%$), model dianggap underfitting. Solusi: tambah fitur baru melalui feature engineering atau gunakan model yang lebih kompleks.
Bias-Variance Naive Bayes	Cenderung high bias / low variance. Asumsi independensi fitur menyebabkan model tidak dapat menangkap pola kompleks (bias tinggi), namun prediksi antar percobaan konsisten (variance rendah).
Bias-Variance Random Forest	Cenderung low bias / high variance. Setiap tree yang dalam cenderung overfitting (variance tinggi), namun averaging dari banyak tree mereduksi variance keseluruhan. Hyperparameter tuning mengontrol keseimbangan ini.

Tabel 16. Rencana Analisis Overfitting dan Bias-Variance Tradeoff

BAB VI

RENCANA DEPLOYMENT MODEL

6.1 Bentuk Deployment

Platform Terpilih	Streamlit Web Application — framework Python open-source untuk membangun aplikasi web data science secara cepat tanpa perlu keahlian frontend.
Alasan Pemilihan	(1) Dapat diimplementasikan sepenuhnya dengan Python tanpa HTML/CSS/JavaScript. (2) Antarmuka interaktif (slider, dropdown, button) tersedia built-in. (3) Deployment gratis via Streamlit Community Cloud. (4) Cocok untuk prototype akademik dan demonstrasi model.
Alternatif	FastAPI + HTML form dapat digunakan sebagai alternatif untuk deployment yang lebih production-ready, namun memerlukan pengetahuan backend tambahan.

Tabel 17. Bentuk Deployment

6.2 Alur Inference: Input - Proses – Output

1. User Input	Isi form di browser.
2. Validasi	Cek kelengkapan input.
3. Preprocessing	Encode & scale input.
4. Load Model	Muat rf_model.pkl.
5. Predict	model.predict(X).
6. Probabilitas	predict_proba(X).
7. Tampilkan	Hasil + penjelasan.

Tabel 18. Alur Inference

Format Input	Form interaktif Streamlit: Pclass (selectbox 1/2/3), Sex (selectbox Male/Female), Age (slider 0-80), SibSp (number_input 0-8), Parch (number_input 0-6), Fare (number_input), Embarked (selectbox C/Q/S).
Proses Internal	Input dari form dikonversi ke DataFrame pandas, kemudian melewati fungsi preprocessing (encoding + scaling menggunakan scaler.pkl yang telah disimpan), lalu diberikan ke model rf_model.pkl untuk prediksi.
Format Output	(1) Label prediksi: 'SELAMAT' atau 'TIDAK SELAMAT' dengan warna hijau/merah. (2) Probabilitas keyakinan model dalam persen. (3) Bar chart feature importance untuk menjelaskan faktor-faktor yang mempengaruhi prediksi.

Tabel 19. Input-Proses-Output

6.3 Arsitektur Sistem dan Struktur File

Struktur Folder	titanic-predictor/ app.py Script utama Streamlit (antarmuka web) train.py Script training & menyimpan model model/ rf_model.pkl Model Random Forest (disimpan via joblib) scaler.pkl StandardScaler (di-fit pada training data)
-----------------	---

	utils/ preprocessing.py Fungsi encoding dan scaling untuk inference data/ titanic.csv Dataset asli dari Kaggle requirements.txt streamlit, scikit-learn, pandas, joblib, matplotlib.
Cara Simpan Model	Setelah training selesai: joblib.dump(best_rf_model, 'model/rf_model.pkl') dan joblib.dump(scaler, 'model/scaler.pkl'). Penting: scaler harus di-fit hanya pada X_train untuk mencegah data leakage saat inference.
Cara Load & Inference	Di app.py: model = joblib.load('model/rf_model.pkl') dan scaler = joblib.load('model/scaler.pkl'). Input user diproses: X_input = preprocess(user_data, scaler), kemudian pred = model.predict(X_input) dan prob = model.predict_proba(X_input).

Tabel 20. Arsitektur Sistem dan Struktur File

BAB VII

TIMELINE Pengerjaan Proyek

Minggu	Fase	Kegiatan Umum	Output
Minggu 1	Persiapan & EDA	Download dataset Kaggle, eksplorasi data (EDA), visualisasi distribusi fitur, analisis missing values dan imbalance.	Notebook EDA, laporan karakteristik data.
Minggu 2	Preprocessing	Handling missing values, encoding kategorikal, feature scaling, feature engineering (FamilySize, IsAlone).	Dataset bersih siap modeling.
Minggu 3	Modeling Baseline	Implementasi Gaussian Naive Bayes, training, evaluasi awal dengan train/test split.	Baseline model + metrik awal.
Minggu 4	Modeling Utama	Implementasi Random Forest, Grid Search CV hyperparameter tuning, 5-Fold Cross Validation.	Model RF teroptimasi.
Minggu 5	Evaluasi & Analisis	Perbandingan performa kedua model, confusion matrix, feature importance, analisis overfitting.	Laporan evaluasi lengkap.
Minggu 6	Deployment	Implementasi aplikasi Streamlit, testing inference, dokumentasi kode.	Aplikasi Streamlit berjalan.
Minggu 7	Finalisasi	Penyusunan laporan akhir, review kode, persiapan presentasi UAS.	Laporan & kode final.

Tabel 21. Timeline Pengerjaan Proyek

DAFTAR REFERENSI

- [1] YasserH. (2021). Titanic Dataset. Kaggle.
<https://www.kaggle.com/datasets/yasserh/titanic-dataset>
- [2] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.
<https://doi.org/10.1023/A:1010933404324>
- [3] Zhang, H. (2004). The Optimality of Naive Bayes. Proceedings of the 17th International FLAIRS Conference, 562-567.
- [4] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- [5] McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference, 51-56.
- [6] Geron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.). O'Reilly Media.
- [7] Vanderplas, J. (2016). Python Data Science Handbook: Essential Tools for Working with Data. O'Reilly Media.
- [8] Streamlit Inc. (2023). Streamlit Documentation. <https://docs.streamlit.io>

NIM : A11.2024.15611
NAMA : BUNGALUNNA NASHUHA CAMELIA
KELAS : A11.4404
MATA KULIAH : PEMBELAJARAN MESIN

UTS SOAL 1-5

Prediksi Keselamatan Penumpang Titanic Menggunakan Machine Learning

Soal 1: PROBLEM FORMULATION & LEARNING TASK

1.1 Latar Belakang Masalah

Pada tanggal 15 April 1912, kapal RMS Titanic tenggelam setelah menabrak gunung es di Samudra Atlantik Utara. Dari 2.224 penumpang dan awak kapal, lebih dari 1.500 orang meninggal dunia, menjadikannya salah satu bencana maritim paling mematikan dalam sejarah. Data historis menunjukkan bahwa peluang keselamatan tidak merata di antara para penumpang. Faktor seperti kelas tiket, jenis kelamin, dan usia terbukti berpengaruh besar terhadap siapa yang selamat. Pertanyaan utama yang ingin dijawab: dapatkah model Machine Learning memprediksi secara akurat apakah seorang penumpang selamat atau tidak, berdasarkan data demografis dan informasi tiket mereka?

1.2 Mengapa Machine Learning Diperlukan?

Rule-Based	Pendekatan berbasis aturan (contoh: wanita dan anak-anak diselamatkan lebih dulu) hanya menangkap pola sederhana dan tidak mampu mempertimbangkan interaksi kompleks antar beberapa fitur secara bersamaan.
Machine Learning	Model ML dapat mempelajari pola kompleks dari data secara otomatis, menangkap interaksi non-linear antar fitur, dan

	memberikan probabilitas prediksi yang lebih informatif tanpa perlu mendefinisikan aturan secara manual.
--	---

1.3 Definisi Learning Task

Jenis Task	Supervised Learning - Klasifikasi Biner. Model dilatih menggunakan data berlabel (kolom target Survived) untuk memprediksi satu dari dua kelas: selamat (1) atau tidak selamat (0).
Target / Label	Kolom Survived: 0 = Tidak Selamat, 1 = Selamat
Input Features	Pclass (kelas tiket), Sex (jenis kelamin), Age (usia), SibSp (jumlah saudara/pasangan di kapal), Parch (jumlah orang tua/anak di kapal), Fare (harga tiket), Embarked (pelabuhan keberangkatan).

1.4 Hipotesis Awal

Hipotesis 1	Random Forest akan menghasilkan akurasi lebih tinggi dibandingkan Naive Bayes karena mampu menangkap interaksi non-linear antar fitur dan lebih robust terhadap outlier pada fitur numerik seperti Age dan Fare.
Hipotesis 2	Fitur Sex dan Pclass akan menjadi prediktor terkuat keselamatan penumpang, karena secara historis wanita dan penumpang kelas 1 memiliki prioritas evakuasi yang lebih tinggi.
Hipotesis 3	Model akan mencapai akurasi di atas 80% pada data uji setelah dilakukan preprocessing yang tepat, dengan F1-Score minimal 0.78.

Soal 2: DATASET & REPRESENTASI DATA

2.1 Sumber Dataset

Nama	Titanic Dataset
Sumber	Kaggle-Platform dataset publik terkurasi
URL	https://www.kaggle.com/datasets/yasserh/titanic-dataset
Status	Publik - CC0 (Public Domain), bebas digunakan untuk riset dan pendidikan
Ukuran	891 baris (penumpang) x 12 kolom (fitur)
Struktur Data	Data tabular (structured data) dalam format CSV

2.2 Tabel Deskripsi Fitur

Fitur	Tipe Data	Deskripsi	Peran
PassengerId	Integer	ID unik tiap penumpang	Dihapus
Survived	Integer (0/1)	0=tidak selamat, 1=selamat	Target Label
Pclass	Integer (1/2/3)	Kelas tiket: 1 (atas), 2 (menengah), 3 (bawah)	Fitur Input
Name	String	Nama lengkap penumpang	Dihapus
Sex	Kategorikal	Jenis kelamin: male / female	Fitur Input
Age	Float	Usia dalam tahun	Fitur Input
SibSp	Integer	Jumlah saudara/pasangan di kapal	Fitur Input
Parch	Integer	Jumlah orang tua/anak di kapal	Fitur Input
Ticket	String	Nomor tiket (tidak terstruktur)	Dihapus
Fare	Float	Harga tiket yang dibayarkan	Fitur Input
Cabin	String	Nomor kabin	Dihapus (77% kosong)
Embarked	Kategorikal	Pelabuhan: C / Q / S	Fitur Input

2.3 Analisis Representasi Data

Fitur vs Target	Fitur input yang digunakan setelah seleksi: Pclass, Sex, Age, SibSp, Parch, Fare, Embarked (7 fitur). Target: Survived (biner 0/1).
Potensi Bias	Dataset mencerminkan kebijakan evakuasi era 1912 sehingga model sangat bergantung pada fitur Sex. Ini bukan bias teknis melainkan pola historis yang nyata dalam data.
Potensi Imbalance	549 tidak selamat (61.6%) vs 342 selamat (38.4%). Ketidakseimbangan moderat ~60:40 - gunakan F1-Score dan ROC-AUC, bukan hanya akurasi sebagai metrik utama.

2.4 Identifikasi Tantangan Dataset

Missing Values	Age: 177 baris kosong (19.9%) - diisi dengan nilai median. Cabin: 687 baris kosong (77.1%) - kolom dihapus. Embarked: 2 baris kosong diisi dengan modus (S).
Noise / Outlier	Kolom Fare memiliki nilai ekstrem - penumpang kelas 1 dengan harga tiket sangat tinggi. Akan ditangani dengan StandardScaler atau RobustScaler saat preprocessing.
Dimensionality	Tidak ada masalah dimensionalitas tinggi - hanya 7 fitur. Setelah One-Hot Encoding pada Embarked, jumlah fitur menjadi 9 fitur total.

Soal 3: MACHINE LEARNING PIPELINE DESIGN

3.1 Pipeline Workflow End-to-End

1. Input Data	CSV dari Kaggle.
2. Data Cleaning	Handle missing, drop kolom.
3. Encoding	Label/OHE kategorikal.
4. Scaling	StandardScaler numerik.
5. Split Data	Train 80% / Test 20%.
6. Training	Naive Bayes & RF.
7. Evaluasi	Metrics & CM.
8. Output	Prediksi Survived.

3.2 Data Preprocessing

Cleaning	1. Hapus kolom tidak relevan: PassengerId, Name, Ticket, Cabin. 2. Isi missing value Age dengan nilai median (robust terhadap outlier). 3. Isi missing value Embarked dengan modus (S).
Encoding	1. Sex: Label Encoding (male=0, female=1). 2. Embarked: One-Hot Encoding menghasilkan Embarked_C, Embarked_Q, Embarked_S dengan drop_first=True untuk menghindari multikolinearitas.
Scaling	Kolom numerik (Age, Fare, SibSp, Parch) dinormalisasi menggunakan StandardScaler (mean=0, std=1) agar model tidak bias terhadap fitur dengan rentang nilai besar seperti Fare.

3.3 Feature Engineering

FamilySize	Fitur baru: $\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$. Merepresentasikan total anggota keluarga di kapal, berpotensi lebih informatif dibanding SibSp dan Parch secara terpisah.
IsAlone	Fitur biner: $\text{IsAlone} = 1$ jika $\text{FamilySize} == 1$, else 0. Penumpang yang bepergian sendiri mungkin memiliki pola keselamatan berbeda dari yang bersama keluarga.

3.4 Data Splitting Strategy

Train/Test Split	Rasio 80% training (712 data) dan 20% testing (179 data) menggunakan <code>random_state=42</code> untuk memastikan hasil reproducible di setiap percobaan.
Stratified Split	Menggunakan <code>stratify=y</code> pada <code>train_test_split</code> agar proporsi kelas Survived tetap seimbang (~60:40) di training set maupun testing set.
Cross Validation	5-Fold Stratified Cross Validation pada training set untuk validasi performa yang lebih stabil dan menghindari overfitting terhadap satu split tertentu.

Soal 4: MODELING STRATEGY & EXPERIMENT DESIGN

4.1 Pemilihan Algoritma

Algoritma 1: Gaussian Naive Bayes	Cara Kerja: Menghitung probabilitas setiap kelas menggunakan Teorema Bayes dengan asumsi setiap fitur bersifat independen dan berdistribusi Gaussian (normal). Prediksi berdasarkan kelas dengan probabilitas posterior tertinggi. Alasan Pemilihan: Sederhana, cepat, dan efektif sebagai model baseline. Cocok untuk fitur numerik kontinu seperti Age dan Fare. Tidak memerlukan banyak hyperparameter dan mudah diinterpretasikan.
Algoritma 2: Random Forest	Cara Kerja: Membangun banyak Decision Tree secara paralel menggunakan bootstrap sampling pada subset data dan fitur yang dipilih acak. Prediksi akhir melalui voting mayoritas dari semua tree. Alasan Pemilihan: Lebih akurat dari Naive Bayes karena menangkap interaksi non-linear antar fitur. Robust terhadap outlier. Menghasilkan feature importance yang berguna untuk interpretasi model.

4.2 Rancangan Eksperimen & Hyperparameter Tuning

Metode Tuning	Grid Search CV (GridSearchCV dari scikit-learn) dengan 5-Fold Stratified CV. Dipilih karena
----------------------	---

	jumlah hyperparameter tidak terlalu banyak sehingga masih komputasional efisien.
HP Naive Bayes	var_smoothing: [1e-9, 1e-8, 1e-7, 1e-6, 1e-5] - mengontrol stabilitas estimasi varians Gaussian.
HP Random Forest	n_estimators: [100, 200, 300] max_depth: [None, 5, 10, 15] min_samples_split: [2, 5, 10] max_features: [sqrt, log2]
Cross Validation	5-Fold Stratified CV pada seluruh pipeline (preprocessing + model) untuk mencegah data leakage dan mendapatkan estimasi performa yang lebih generalisasi.

4.3 Metrik Evaluasi

Metrik	Formula/Deskripsi	Alasan Penggunaan
Accuracy	$\frac{TP+TN}{TP+TN+FP+FN}$	Gambaran umum performa model
Precision	$\frac{TP}{TP+FP}$	Ketepatan prediksi kelas selamat
Recall	$\frac{TP}{TP+FN}$	Kemampuan mendeteksi semua penumpang selamat
F1-Score	$2 \times \frac{P \times R}{P+R}$	Keseimbangan Precision & Recall (penting krn imbalance)
ROC-AUC	Area Under ROC Curve	Performa model keseluruhan lintas threshold
Confusion Matrix	Matriks TP, TN, FP, FN	Analisis detail kesalahan prediksi

4.4 Rencana Analisis Overfitting & Bias-Variance Tradeoff

Overfitting vs Underfitting	Dibandingkan training accuracy vs validation accuracy (CV). Jika training accuracy jauh lebih tinggi dari CV accuracy maka overfitting tangani dengan membatasi max_depth atau menambah min_samples_split. Jika keduanya rendah maka underfitting - tambah fitur baru atau gunakan model lebih kompleks.
Bias-Variance Tradeoff	Naive Bayes: cenderung high bias/low variance - bisa underfitting jika asumsi independensi fitur tidak terpenuhi. Random Forest: cenderung low bias/high variance - bisa overfitting jika max_depth tidak dibatasi. Hyperparameter tuning bertujuan menemukan keseimbangan optimal antara bias dan variance.

Soal 5: MODEL DEPLOYMENT PLAN (INFERENCE DESIGN)

5.1 Bentuk Deployment

Platform	Streamlit Web Application - dipilih karena mudah diimplementasikan dengan Python murni tanpa perlu membangun backend terpisah, cocok untuk prototype dan demonstrasi akademik.
Alasan Streamlit	Tidak memerlukan HTML/CSS/JavaScript. Kode

	Python langsung menjadi antarmuka web interaktif. Deployment gratis melalui Streamlit Community Cloud.
--	--

5.2 Alur Inference: Input - Model – Output

1. User Input	Isi form data penumpang di web
2. Preprocessing	Encoding & Scaling input
3. Load Model	rf_model.pkl via joblib
4. Inference	model.predict(X_input)
5. Output	Tampilkan prediksi & probabilitas

Format Input	Form Streamlit dengan field: Pclass (Dropdown 1/2/3), Sex (Dropdown Male/Female), Age (Slider 0-80 tahun), SibSp (Number 0-8), Parch (Number 0-6), Fare (Number input), Embarked (Dropdown C/Q/S).
Format Output	Hasil prediksi: Label SELAMAT atau TIDAK SELAMAT, probabilitas keyakinan model dalam persen, dan grafik feature importance untuk menjelaskan faktor yang paling berpengaruh.

5.3 Struktur Sistem & Arsitektur Sederhana

Struktur Folder	titanic-app/ app.py (Script utama Streamlit) model/ rf_model.pkl (Model RF tersimpan via joblib) scaler.pkl (StandardScaler tersimpan) utils/ preprocessing.py
------------------------	--

	(Fungsi encoding & scaling input) requirements.txt (streamlit, scikit-learn, pandas, joblib)
Model File	Setelah training selesai, model terbaik disimpan dengan <code>joblib.dump(model, 'model/rf_model.pkl')</code> dan <code>scaler.pkl</code> disimpan terpisah agar preprocessing saat inference konsisten dengan saat training.
Script Inference	app.py: (1) Baca input dari form Streamlit, (2) Panggil <code>preprocessing.py</code> untuk encoding & scaling, (3) Muat <code>rf_model.pkl</code> dengan <code>joblib.load()</code> , (4) Jalankan <code>model.predict()</code> dan <code>model.predict_proba()</code> , (5) Tampilkan hasil ke antarmuka pengguna.

Referensi:

- [1] YasserH. (2021). Titanic Dataset. Kaggle.
<https://www.kaggle.com/datasets/yasserh/titanic-dataset>
- [2] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.
- [3] Zhang, H. (2004). The Optimality of Naive Bayes. Proc. 17th FLAIRS Conference, 562-567.
- [4] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12, 2825-2830.
- [5] Geron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.). O'Reilly.
- [6] McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proc. SciPy 2010, 51-56.