

**PROPOSAL PEMBELAJARAN MESIN
KLASIFIKASI KUALITAS UDARA BERDASARKAN
PARAMETER METEOROLOGI MENGGUNAKAN
MACHINE LEARNING**

Dosen Pengampu :

Abu Salam M.Kom

Disusun oleh:

Sabrina Angel Lilga Putri Maharani – A11.2024.15596

**PROGRAM STUDI TEKNIK INFORMATIKA
UNIVERSITAS DIAN NUSWANTORO SEMARANG
TAHUN 2026/2027**

DAFTAR ISI

BAB I PENDAHULUAN3

1.1 Latar Belakang3

1.2 Mengapa Machine Learning Diperlukan?3

1.3 Definisi Learning Task4

BAB II RUMUSAN MASALAH5

2.1 Identifikasi Masalah5

2.2 Tujuan Proyek5

2.3 Hipotesis Awal6

BAB III ANALISIS DATASET DAN REPRESENTASI DATA7

3.1 Informasi Dataset7

3.2 Deskripsi Fitur7

3.3 Analisis Karakteristik Data8

3.4 Identifikasi Tantangan Dataset9

BAB IV PERANCANGAN PIPELINE MACHINE LEARNING10

4.1 Gambaran Umum Pipeline10

4.2 Tahap 1 – Exploratory Data Analysis (EDA)11

4.3 Tahap 2 – Data Preprocessing11

4.4 Tahap 3 – Feature Engineering12

4.5 Tahap 4 – Data Splitting Strategy12

BAB V STRATEGI PEMODELAN DAN EKSPERIMEN13

5.1 Algoritma yang Digunakan13

5.2 Logistic Regression (Baseline Model)13

5.3 Random Forest Classifier (Model Utama)14

5.4 Rancangan Eksperimen dan Hyperparameter Tuning14

5.5 Metrik Evaluasi15

BAB VI RENCANA DEPLOYMENT MODEL16

BAB VII TIMELINE Pengerjaan Proyek17

BAB VIII KESIMPULAN18

DAFTAR PUSTAKA19

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kualitas udara merupakan salah satu indikator kesehatan lingkungan yang paling kritis di era industrialisasi dan urbanisasi. Kota-kota besar di Indonesia, termasuk Semarang, menghadapi tantangan serius berupa peningkatan konsentrasi polutan udara akibat emisi kendaraan bermotor, aktivitas industri, dan pembakaran bahan bakar fosil yang tidak terkendali.

Pemantauan kualitas udara secara konvensional sangat bergantung pada sensor polutan khusus seperti PM_{2.5}, PM₁₀, NO₂, SO₂, dan CO yang memiliki biaya instalasi dan perawatan yang tinggi. Akibatnya, jaringan pemantauan kualitas udara di banyak daerah masih sangat terbatas. Di sisi lain, data meteorologi seperti suhu, kelembaban relatif, kecepatan angin, tekanan udara, dan radiasi matahari jauh lebih mudah diukur dan tersedia secara luas melalui stasiun cuaca yang sudah tersebar di berbagai wilayah.

Pertanyaan utama yang ingin dijawab dalam penelitian ini adalah: dapatkah parameter meteorologi saja digunakan sebagai prediktor yang akurat untuk mengklasifikasikan tingkat kualitas udara menggunakan model Machine Learning?

1.2 Mengapa Machine Learning Diperlukan?

Pendekatan konvensional dalam pemantauan kualitas udara memerlukan sensor polutan langsung yang mahal dan tidak terdistribusi secara merata. Selain itu, metode statistik tradisional kesulitan menangkap hubungan non-linear yang kompleks antara variabel meteorologi dan kondisi kualitas udara.

Machine Learning menawarkan solusi yang lebih adaptif karena kemampuannya dalam mempelajari pola hubungan non-linear secara otomatis dari data historis. Dengan memanfaatkan parameter meteorologi sebagai fitur input, model ML dapat memprediksi kategori kualitas udara tanpa memerlukan sensor polutan langsung, sehingga sistem pemantauan dapat dikembangkan dengan biaya lebih rendah dan cakupan wilayah yang lebih luas.

1.3 Definisi Learning Task

Permasalahan dalam penelitian ini termasuk dalam kategori Supervised Learning, khususnya klasifikasi multi-kelas. Dataset yang digunakan telah memiliki label kualitas udara yang jelas, sehingga model dapat dilatih untuk mempelajari hubungan antara parameter meteorologi sebagai input dan kategori kualitas udara sebagai output.

Target atau label yang digunakan adalah variabel Air Quality, dengan nilai:

- Good — Kualitas udara baik, aman bagi semua kelompok
- Moderate — Kualitas udara cukup, beberapa kelompok sensitif mungkin terpengaruh
- Poor — Kualitas udara buruk, berbahaya bagi kelompok sensitif
- Hazardous — Kualitas udara sangat berbahaya bagi semua orang

Adapun fitur input utama yang diuji dalam penelitian ini difokuskan pada parameter meteorologi dan kondisi lingkungan lingkungan, seperti **Suhu (Temperature)**, **Kelembaban (Humidity)**, **Jarak ke Kawasan Industri (Proximity to Industrial)**, dan **Kepadatan Populasi (Population Density)**. Fitur polutan kimia PM2.5, PM10, NO2, SO2, CO yang ada pada dataset awal **hanya akan digunakan sebagai pembanding (kontrol)** dan tidak dimasukkan ke dalam model prediksi utama.

BAB II

RUMUSAN MASALAH

2.1 Identifikasi Masalah

- Bagaimana membangun model Machine Learning yang mampu mengklasifikasikan tingkat kualitas udara berdasarkan parameter meteorologi dan lingkungan?
- Algoritma klasifikasi mana yang memberikan performa terbaik — Logistic Regression atau Random Forest — untuk kasus klasifikasi kualitas udara multi-kelas?
- Parameter meteorologi atau lingkungan mana yang paling dominan dalam menentukan kategori kualitas udara?
- Bagaimana menangani ketidakseimbangan kelas yang mungkin ada pada dataset agar model dapat belajar secara optimal di semua kategori?
- Metrik evaluasi apa yang paling tepat untuk mengukur kinerja model dalam kasus klasifikasi multi-kelas kualitas udara?

2.2 Tujuan Proyek

Tujuan dari penelitian ini adalah sebagai berikut:

Tujuan Utama

Membangun model Machine Learning berbasis klasifikasi multi-kelas yang mampu mengklasifikasikan tingkat kualitas udara (Good/Moderate/Poor/Hazardous) berdasarkan parameter meteorologi dan lingkungan yang tersedia dalam dataset.

Tujuan Komparatif

Membandingkan performa dua algoritma Machine Learning, yaitu Logistic Regression dan Random Forest, dalam mengklasifikasikan tingkat kualitas udara menggunakan metrik evaluasi seperti Accuracy, F1-Score, dan ROC-AUC.

Tujuan Analitik

Mengidentifikasi parameter yang paling berpengaruh terhadap klasifikasi kualitas udara menggunakan pendekatan feature importance pada model Random Forest, sehingga dapat memberikan insight yang actionable bagi pemangku kebijakan lingkungan.

2.3 Hipotesis Awal

Berdasarkan karakteristik dataset dan pendekatan yang digunakan, beberapa hipotesis awal dalam penelitian ini adalah sebagai berikut:

1. Model Random Forest diperkirakan akan menghasilkan performa yang lebih baik dibandingkan Logistic Regression, khususnya dalam metrik F1-Score dan ROC-AUC, karena kemampuannya dalam menangkap hubungan non-linear antar parameter meteorologi.
2. Parameter seperti suhu, kelembaban, dan kecepatan angin diperkirakan memiliki kontribusi signifikan terhadap klasifikasi kualitas udara karena faktor-faktor tersebut secara langsung mempengaruhi dispersi dan konsentrasi polutan di atmosfer.
3. Dengan strategi preprocessing dan pemilihan fitur yang tepat, model diharapkan mampu mencapai F1-Score Macro yang tinggi meski menghadapi kemungkinan ketidakseimbangan kelas antar kategori kualitas udara.

BAB III

ANALISIS DATASET DAN REPRESENTASI DATA

3.1 Informasi Dataset

Berikut adalah informasi umum mengenai dataset Air Quality and Pollution Assessment yang digunakan dalam penelitian ini:

Atribut	Detail
Nama Dataset	Air Quality and Pollution Assessment
Sumber	Kaggle — Platform dataset publik terkurasi
Link Dataset	https://www.kaggle.com/datasets/mujtabamatin/air-quality-and-pollution-assessment
Format File	CSV (Comma-Separated Values)
Dimensi Data	5.000 baris (sampel) x 10 kolom (fitur)
Jenis Data	Data tabular terstruktur — seluruh fitur numerik
Target Label	Air Quality: Good, Moderate, Poor, Hazardous
Lisensi	Open Database License — bebas digunakan untuk riset & pendidikan

Tabel 1 Informasi Dataset

3.2 Deskripsi Fitur

Berikut merupakan deskripsi fitur yang terdapat dalam dataset:

Fitur	Tipe	Keterangan	Peran
Temperature	Float	Suhu udara dalam derajat Celsius	Input
Humidity	Float	Kelembaban relatif udara (%)	Input
PM2.5	Float	Konsentrasi partikel halus <2.5 mikron ($\mu\text{g}/\text{m}^3$)	Input
PM10	Float	Konsentrasi partikel kasar <10 mikron ($\mu\text{g}/\text{m}^3$)	Input
NO2	Float	Konsentrasi Nitrogen Dioksida ($\mu\text{g}/\text{m}^3$)	Input
SO2	Float	Konsentrasi Sulfur Dioksida ($\mu\text{g}/\text{m}^3$)	Input
CO	Float	Konsentrasi Karbon Monoksida (ppm)	Input

Fitur	Tipe	Keterangan	Peran
Proximity_to_Industrial	Float	Jarak ke kawasan industri terdekat (km)	Input
Population_Density	Float	Kepadatan populasi (jiwa/km ²)	Input
Air_Quality	String	Label target: Good/Moderate/Poor/Hazardous	Target

Tabel 2 Deskripsi Fitur Dataset

3.3 Analisis Karakteristik Data

3.3.1 Distribusi Label (Target)

Kelas	Persentase (Estimasi)	Kesimpulan
Good	~25%	Kondisi udara baik, aman untuk semua
Moderate	~25%	Kondisi udara sedang
Poor	~25%	Kondisi berbahaya untuk kelompok sensitif
Hazardous	~25%	Kondisi sangat berbahaya
Total	100%	Distribusi relatif seimbang antar kelas

Tabel 3 Distribusi Label

Dataset ini memiliki distribusi kelas yang relatif seimbang. Namun evaluasi tetap menggunakan F1-Score Macro untuk memastikan performa yang merata di semua kelas.

3.3.2 Research Gap

Mayoritas penelitian klasifikasi kualitas udara yang ada menggunakan data polutan (PM2.5, NO2, CO) sebagai input utama model. Gap penelitian ini terletak pada pengujian apakah parameter meteorologi (suhu, kelembaban, kecepatan angin) saja sudah cukup kuat sebagai prediktor kualitas udara. Pendekatan ini memiliki nilai praktis yang tinggi karena sensor cuaca jauh lebih murah, lebih banyak tersebar, dan lebih mudah diakses dibandingkan sensor polutan khusus.

3.4 Identifikasi Tantangan Dataset

Tantangan	Detail	Strategi Penanganan
Skala Fitur Bervariasi	Suhu (0-50°C), Kepadatan Populasi (ratusan-ribuan), PM2.5 (0-500 $\mu\text{g}/\text{m}^3$) memiliki skala sangat berbeda	StandardScaler untuk normalisasi semua fitur numerik
Klasifikasi Multi-kelas	4 kelas output memerlukan strategi evaluasi yang berbeda dari klasifikasi biner	F1-Score Macro, Confusion Matrix per kelas, One-vs-Rest ROC-AUC
Feature Importance Interpretasi	Perlu memahami fitur meteorologi mana yang paling berpengaruh untuk insight kebijakan	Feature Importance dari Random Forest + SHAP values
Kebocoran Data (<i>Data Leakage</i>) dan Kontradiksi Tujuan Riset	Jika fitur polutan langsung PM2.5, PM10, dkk. ikut dimasukkan, model akan mengalami <i>overfitting</i> yang semu karena label kualitas udara diturunkan langsung dari nilai polutan tersebut.	Menerapkan eksperimen Studi Ablasi Fitur (Feature Ablation Study), yaitu dengan mengisolasi dan menghapus (<i>drop</i>) seluruh fitur polutan langsung sebelum proses pelatihan model utama dilakukan.

Tabel 4 Tantangan Dataset

BAB IV

PERANCANGAN PIPELINE MACHINE LEARNING

4.1 Gambaran Umum Pipeline

Pipeline Machine Learning dalam penelitian ini dirancang secara end-to-end untuk mengolah data parameter meteorologi dan lingkungan hingga menghasilkan prediksi klasifikasi kualitas udara secara akurat.

NO	Tahap	Proses Utama	Output
1	Input Data	Muat CSV dari Kaggle	DataFrame 5.000 x 10
2	EDA	Eksplorasi distribusi kelas, korelasi antar fitur, visualisasi parameter per kelas	Pemahaman karakteristik data
3	Preprocessing	StandardScaler semua fitur numerik, encoding label target	Dataset siap modeling
4	Feature Eng.	Analisis feature importance awal, pertimbangkan rasio atau interaksi fitur meteorologi	Fitur tambahan jika relevan
5	Split Data	Train 80% / Test 20% dengan stratify	Train: 4.000 Test: 1.000
6	Training	Latih 2 model dengan hyperparameter tuning	Model LR dan RF terlatih
7	Evaluasi	F1-Score Macro, ROC-AUC, Confusion Matrix, Feature Importance	Laporan performa lengkap
8	Dokumentasi	Simpan model, susun laporan riset di GitHub	Notebook + Laporan final

Tabel 5 Gambaran Umum Pipeline Machine Learning

4.2 Tahap 1 – Exploratory Data Analysis (EDA)

Sebelum preprocessing, dilakukan eksplorasi data untuk memahami karakteristik dataset:

- Visualisasi distribusi label Air Quality (bar chart) untuk memahami proporsi kelas.
- Distribusi setiap fitur meteorologi berdasarkan kelas — histogram terpisah per kategori kualitas udara.
- Heatmap korelasi antar fitur numerik untuk mendeteksi multikolinearitas.
- Boxplot distribusi Temperature, Humidity, PM2.5, PM10 per kelas untuk mengidentifikasi fitur paling diskriminatif.
- Scatter plot Temperature vs Humidity dengan warna berdasarkan kelas untuk melihat separasi visual antar kelas.

4.3 Tahap 2 – Data Preprocessing

Langkah	Aksi	Alasan
1. Scaling Fitur	StandardScaler pada semua fitur numerik (Temperature, Humidity, PM2.5, PM10, NO2, SO2, CO, Proximity, Population)	Menyamakan skala antar fitur yang sangat berbeda rentangnya agar tidak ada fitur yang mendominasi model
2. Encoding Label	Label Encoding pada kolom Air_Quality: Good=0, Moderate=1, Poor=2, Hazardous=3	Konversi label string ke numerik untuk keperluan training model
3. Cek Missing Values	Verifikasi kelengkapan data — dataset diklaim bersih tanpa missing values	Konfirmasi kualitas data sebelum modeling
4. Scaler Fit Policy	Fit scaler HANYA pada X_train, transform ke X_train dan X_test	Mencegah data leakage — informasi statistik dari test set tidak boleh masuk ke proses training
5. Feature Drop (Studi Ablasi)	Menghapus kolom PM2.5, PM10, NO2, SO2, dan CO dari matriks fitur X sebelum <i>split data</i> .	Memastikan model benar-benar melakukan prediksi hanya berbasis parameter meteorologi dan lingkungan tanpa bantuan sensor kimia, sesuai dengan batasan masalah dan <i>research gap</i> .

Tabel 6 Tahapan Data Preprocessing

4.4 Tahap 3 – Feature Engineering

Fitur Baru	Formula	Hipotesis
PM_ratio	$PM_ratio = PM2.5 / (PM10 + 1)$	Rasio PM2.5 terhadap PM10 mencerminkan proporsi partikel sangat halus — indikator sumber polusi tertentu (kendaraan vs industri)
Heat_Humidity_Index	$HHI = Temperature * Humidity / 100$	Kombinasi suhu dan kelembaban berpengaruh pada reaksi kimia atmosfer yang membentuk polutan sekunder

Tabel 7 Feature Engineering

4.5 Tahap 4 – Data Splitting Strategy

Strategi	Detail
Train/Test Split	Rasio 80% training (4.000 data) dan 20% testing (1.000 data) dengan random_state=42

Strategi	Detail
Stratified Sampling	Parameter stratify=y wajib digunakan agar proporsi semua kelas (Good/Moderate/Poor/Hazardous) terjaga di kedua subset
Cross Validation	5-Fold Stratified Cross Validation pada training set untuk estimasi performa yang stabil

Tabel 8 Strategi Data Splitting

BAB V

STRATEGI PEMODELAN DAN EKSPERIMEN

5.1 Algoritma yang Digunakan

Dalam penelitian ini digunakan dua algoritma Machine Learning: Logistic Regression sebagai baseline model dan Random Forest sebagai model utama. Pemilihan kedua algoritma ini didasarkan pada keseimbangan antara interpretabilitas dan kemampuan menangani kompleksitas data multi-kelas.

5.2 Logistic Regression (Baseline Model)

Aspek	Detail
Kelebihan	Sangat cepat dalam training. Highly interpretable: koefisien menunjukkan kontribusi tiap fitur. Probabilitas terkalibrasi baik untuk multi-kelas dengan pendekatan One-vs-Rest (OvR).
Kekurangan	Hanya menangkap hubungan linear — kemungkinan underfitting jika interaksi non-linear antar parameter meteorologi dominan.
Konfigurasi	<code>multi_class='ovr', class_weight='balanced', max_iter=1000, solver='lbfgs'</code>
Peran	Model baseline untuk mengukur seberapa besar peningkatan performa dari Random Forest pada kasus klasifikasi kualitas udara.

Tabel 9 Konfigurasi Logistic Regression

5.3 Random Forest Classifier (Model Utama)

Aspek	Detail
Kelebihan	Akurasi tinggi pada data multi-kelas. Robust terhadap outlier. Mampu menangkap interaksi non-linear antar parameter. Menghasilkan feature importance untuk interpretasi kontribusi tiap fitur meteorologi.
Kekurangan	Lebih lambat dibanding Logistic Regression untuk dataset besar. Model lebih sulit diinterpretasikan secara individual (black box ensemble).
Konfigurasi	<code>n_estimators=100-300, max_depth=None/10/20, min_samples_split=2/5, class_weight='balanced'</code>
Peran	Model utama dengan harapan F1-Score Macro dan ROC-AUC tertinggi untuk klasifikasi kualitas udara 4 kelas.

Tabel 10 Konfigurasi Random Forest

5.4 Rancangan Eksperimen dan Hyperparameter Tuning

Aspek	Detail
Metode Tuning	GridSearchCV dari scikit-learn dengan 5-Fold Stratified Cross Validation
Metrik Optimasi	F1-Score Macro (scoring='f1_macro') dipilih karena dataset multi-kelas dan penting untuk performa merata di semua kategori kualitas udara
Grid Logistic Regression	C: [0.001, 0.01, 0.1, 1, 10, 100] solver: [lbfgs] class_weight: [balanced] max_iter: [1000]
Grid Random Forest	n_estimators: [100, 200, 300] max_depth: [None, 10, 20] min_samples_split: [2, 5] min_samples_leaf: [1, 2] class_weight: [balanced]

Tabel 11 Rancangan Eksperimen

Untuk menjamin adanya aktivitas riset yang valid, pengujian tidak hanya dilakukan pada satu kondisi data matang. Eksperimen dibagi menjadi dua skenario pengujian komparatif:

1. Skenario A (Baseline): Model dilatih menggunakan seluruh fitur bawaan dataset (10 kolom termasuk polutan).
2. Skenario B (Ablasi/Riset Utama): Model dilatih setelah fitur polutan langsung dihapus (hanya menyisakan fitur cuaca dan lingkungan).

Kedua skenario ini akan dibandingkan menggunakan F1-Score Macro untuk melihat seberapa tangguh parameter meteorologi murni dalam menggantikan peran sensor polutan yang mahal.

5.5 Metrik Evaluasi

Metrik	Formula	Interpretasi	Prioritas
F1-Score Macro	Rata-rata F1 tiap kelas	Mengukur performa merata di semua kategori kualitas udara — penting karena semua kelas sama pentingnya	UTAMA
Accuracy	$(TP+TN)/Total$	Proporsi prediksi benar keseluruhan — relevan karena distribusi kelas relatif seimbang	UTAMA
ROC-AUC (OvR)	Area Under ROC per kelas	Kemampuan model membedakan tiap kelas dari yang lain di semua threshold	UTAMA
Confusion Matrix	TP, TN, FP, FN per kelas	Analisis detail kesalahan klasifikasi antar kategori — mana yang sering tertukar	Diagnostik
Feature Importance	Impurity-based (RF)	Fitur meteorologi mana yang paling menentukan klasifikasi — insight untuk kebijakan	Analitik

Tabel 12 Metrik Evaluasi Model

BAB VI

RENCANA DEPLOYMENT MODEL

Sesuai dengan ketentuan tugas, output utama dari penelitian ini adalah dokumentasi riset dalam bentuk notebook Google Colab dan laporan yang dikumpulkan melalui GitHub. Deployment dalam bentuk sistem atau API bukan merupakan target utama, namun model yang telah dilatih akan disimpan menggunakan joblib untuk memungkinkan inference di masa mendatang.

Komponen	Detail
Platform Utama	Google Colab — notebook Python end-to-end dari EDA hingga evaluasi model
Penyimpanan Model	joblib.dump() untuk menyimpan model terbaik (rf_best_model.pkl) dan scaler (scaler.pkl)
Repositori	GitHub — berisi notebook .ipynb, laporan, dan file model tersimpan
Struktur Notebook	Section 1: Setup & Load Data Section 2: EDA Section 3: Preprocessing Section 4: Feature Engineering Section 5: Modeling Section 6: Evaluasi & Analisis
Dokumentasi	Setiap cell notebook dilengkapi markdown penjelasan untuk memudahkan pembacaan dan penilaian

Tabel 13 Rencana Deployment dan Dokumentasi

BAB VII

TIMELINE Pengerjaan Proyek

Minggu	Fase	Kegiatan Utama	Output
Minggu 1	Persiapan & EDA	Download dataset, eksplorasi distribusi kelas, analisis korelasi, visualisasi fitur per kelas	Notebook EDA, pemahaman karakteristik data
Minggu 2	Preprocessing	StandardScaler, label encoding, feature engineering PM_ratio & HHI, stratified train/test split	Dataset bersih siap modeling
Minggu 3	Modeling Baseline	Implementasi Logistic Regression dengan class_weight='balanced', training, evaluasi awal	Baseline model + metrik awal
Minggu 4	Modeling Utama	Implementasi Random Forest, GridSearchCV dengan scoring F1 Macro, 5-Fold Stratified CV	Model RF teroptimasi
Minggu 5	Evaluasi & Analisis	Perbandingan performa kedua model, feature importance, confusion matrix, analisis overfitting	Laporan evaluasi lengkap
Minggu 6	Dokumentasi	Penyusunan laporan akhir, review kode, commit ke GitHub, persiapan presentasi UAS	Laporan & kode final di GitHub

Tabel 14 Timeline Pengerjaan Proyek

BAB VIII

KESIMPULAN

Berdasarkan rancangan yang telah disusun, penelitian ini bertujuan untuk membangun sistem klasifikasi kualitas udara berbasis Machine Learning menggunakan parameter meteorologi dan lingkungan sebagai fitur input. Penelitian ini berfokus pada menjawab gap riset yang masih terbuka, yaitu apakah data meteorologi saja sudah cukup untuk memprediksi kategori kualitas udara tanpa harus bergantung pada sensor polutan yang mahal.

Model yang digunakan adalah Logistic Regression dan Random Forest yang akan dibandingkan performanya menggunakan metrik F1-Score Macro, Accuracy, dan ROC-AUC. Analisis feature importance dari Random Forest diharapkan dapat memberikan insight actionable tentang parameter meteorologi mana yang paling berpengaruh terhadap kualitas udara, yang dapat menjadi masukan berharga bagi kebijakan pemantauan lingkungan, khususnya di kota-kota besar Indonesia yang menghadapi masalah polusi udara nyata.

Output akhir penelitian ini adalah dokumentasi riset lengkap dalam bentuk notebook Google Colab yang dapat direproduksi, serta laporan yang tersedia di repositori GitHub.

DAFTAR PUSTAKA

Breiman, L. (2001). Random Forests. *Machine Learning*, 5–32.

Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.

Piracha, A., & Chaudhary, M. T. (2022). Urban Air Pollution, Urban Heat Island and Human Health: A Review of the Literature. *Sustainability*, 14, 9234.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research (JMLR)*, 2825–2830.

Mujtabamatin. (2024). Air Quality and Pollution Assessment — Kaggle. Retrieved from <https://www.kaggle.com/datasets/mujtabamatin/air-quality-and-pollution-assessment>

World Health Organization. (2021). WHO global air quality guidelines: particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. Geneva: WHO.